

# Probabilidad

*Universidad de Málaga*

*Grado en Matemáticas*

*Curso 2023-2024*

---

# Contenidos

---

<b>1. Espacios de probabilidad</b>	<b>4</b>
1.1. Espacios muestrales y $\sigma$ -álgebras . . . . .	4
1.2. Medidas . . . . .	5
<b>2. Funciones de distribución</b>	<b>7</b>
2.1. Nociones básicas . . . . .	7
2.2. Funciones de distribución discretas . . . . .	8
2.3. Funciones de distribución continuas . . . . .	8
2.4. Funciones de distribución absolutamente continuas . . . . .	9
2.5. Funciones de distribución mixtas . . . . .	9
<b>3. Variables aleatorias</b>	<b>11</b>
3.1. Nociones básicas . . . . .	11
3.2. Variables aleatorias simples . . . . .	16
3.3. Cambio de variable . . . . .	17
<b>4. Distribuciones de probabilidad usuales</b>	<b>18</b>
4.1. Distribuciones de probabilidad discretas . . . . .	18
4.2. Distribuciones de probabilidad absolutamente continuas . . . . .	19
<b>5. Probabilidad condicionada</b>	<b>20</b>
5.1. Probabilidad condicionada de sucesos . . . . .	20
5.2. Dependencia e independencia de sucesos . . . . .	21
5.3. Probabilidad condicionada con respecto a una partición . . . . .	22
5.4. Probabilidad condicionada con respecto a una variable aleatoria . . . . .	22
5.5. Variables aleatorias truncadas . . . . .	23
<b>6. Esperanza</b>	<b>24</b>
6.1. Nociones básicas . . . . .	24

6.2. Momentos de una variable aleatoria . . . . .	25
6.3. Función generatriz de probabilidad . . . . .	28
6.4. Función generatriz de momentos . . . . .	30
6.5. Función característica . . . . .	30
6.6. Otras características numéricas . . . . .	31
<b>7. Vectores aleatorios</b>	<b>33</b>
7.1. Nociones básicas . . . . .	33
7.2. Vectores aleatorios bidimensionales . . . . .	34
7.3. Diferencia de una función con respecto a un rectángulo . . . . .	35
7.4. Vectores aleatorios discretos . . . . .	35
7.5. Vectores aleatorios absolutamente continuos . . . . .	38
<b>8. Teorema central del límite</b>	<b>42</b>
8.1. Convergencia en distribución . . . . .	42
8.2. Teorema central del límite . . . . .	42

# Espacios de probabilidad

## 1.1. Espacios muestrales y $\sigma$ -álgebras

**Definición 1.** Al conjunto de todos los posibles resultados de un experimento aleatorio se le llama **espacio muestral**, y se denota por  $\Omega$ .

De aquí en adelante, la letra  $\Omega$  se referirá siempre a un espacio muestral, que no es más que un conjunto arbitrario no vacío.

**Definición 2.** Se dice que una familia de subconjuntos  $\mathcal{A} \subset \mathcal{P}(\Omega)$  es una  **$\sigma$ -álgebra sobre  $\Omega$**  cuando

- (i)  $\Omega \in \mathcal{A}$ .
- (ii) Para todo  $A \in \mathcal{A}$  se tiene que  $A^c \in \mathcal{A}$ .
- (iii) Para toda familia numerable  $\{A_i\}_{i \in I}$  de elementos de  $\mathcal{A}$  se tiene que  $\bigcup_{i \in I} A_i \in \mathcal{A}$ .

Un **suceso** no es más que un elemento de  $\mathcal{A}$ .

**Definición 3.** Dada una familia de subconjuntos  $E \subset \mathcal{P}(\Omega)$ , la menor  $\sigma$ -álgebra sobre  $\Omega$  que contiene a  $E$  se denomina  **$\sigma$ -álgebra generada por  $E$** , y se denota por  $\sigma(E)$ .

**Proposición 1.** Se verifican las siguientes propiedades:

- (i) Si  $E_1, E_2 \subset \mathcal{P}(\Omega)$  son tales que  $E_1 \subset E_2$ , entonces  $\sigma(E_1) \subset \sigma(E_2)$ .
- (ii) Dado  $E \subset \mathcal{P}(\Omega)$ , se tiene que  $\sigma(E) = E$  si y solo si  $E$  es una  $\sigma$ -álgebra sobre  $\Omega$ .

**Demostración.** Se remite a la asignatura *Teoría de la Medida e Integración*. □

**Definición 4.** Sea  $(\Omega, \tau)$  un espacio topológico. La  **$\sigma$ -álgebra de Borel sobre  $\Omega$** , denotada por  $\mathcal{B}(\Omega)$  o  $\mathcal{B}_\Omega$ , es la  $\sigma$ -álgebra generada por  $\tau$ , es decir,  $\mathcal{B}(\Omega) := \sigma(\tau)$ .

**Proposición 2.** La  $\sigma$ -álgebra de Borel de  $\mathbb{R}^n$  junto con la topología usual está generada por cada una de las siguientes familias de intervalos:

- (i)  $\mathcal{E}_1 = \{(a, b) = (a_1, b_1) \times \dots \times (a_n, b_n) : a, b \in \mathbb{R}^n\}$ .
- (ii)  $\mathcal{E}_2 = \{[a, b) = [a_1, b_1) \times \dots \times [a_n, b_n) : a, b \in \mathbb{R}^n\}$ .
- (iii)  $\mathcal{E}_3 = \{(a, b] = (a_1, b_1] \times \dots \times (a_n, b_n] : a, b \in \mathbb{R}^n\}$ .
- (iv)  $\mathcal{E}_4 = \{[a, b] = [a_1, b_1] \times \dots \times [a_n, b_n] : a, b \in \mathbb{R}^n\}$ .
- (v)  $\mathcal{E}_5 = \{(a, +\infty) = (a_1, +\infty) \times \dots \times (a_n, +\infty) : a \in \mathbb{R}^n\}$ .
- (vi)  $\mathcal{E}_6 = \{[a, +\infty) = [a_1, +\infty) \times \dots \times [a_n, +\infty) : a \in \mathbb{R}^n\}$ .
- (vii)  $\mathcal{E}_7 = \{(-\infty, b) = (-\infty, b_1) \times \dots \times (-\infty, b_n) : b \in \mathbb{R}^n\}$ .
- (viii)  $\mathcal{E}_8 = \{(-\infty, b] = (-\infty, b_1] \times \dots \times (-\infty, b_n] : b \in \mathbb{R}^n\}$ .

**Demostración.** Se remite a la asignatura *Teoría de la Medida e Integración*. □

**Definición 5.** Dada una  $\sigma$ -álgebra  $\mathcal{A}$  sobre  $\Omega$ , la dupla  $(\Omega, \mathcal{A})$  se llama **espacio medible**, mientras que la dupla  $(\Omega, \mathcal{B}(\Omega))$ , o simplemente  $(\Omega, \mathcal{B})$ , se denomina **espacio medible-Borel**.

Si no se hace mención alguna sobre cuál es el espacio topológico del que procede una  $\sigma$ -álgebra de Borel  $\mathcal{B}$ , se supondrá siempre que se trata de  $\mathbb{R}$  junto con la topología usual.

## 1.2. Medidas

**Definición 6.** Dado un espacio medible  $(\Omega, \mathcal{A})$ , una **medida positiva** (o simplemente **medida**) es una aplicación  $\mu: \mathcal{A} \rightarrow [0, \infty]$  verificando

(i)  $\mu(\emptyset) = 0$ .

(ii) Si  $\{A_n\}_{n \in \mathbb{N}}$  es una familia de elementos de  $\mathcal{A}$  disjuntos dos a dos, entonces

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n)$$

Esta propiedad suele ser denominada  **$\sigma$ -aditividad**.

**Proposición 3.** Sea  $\mu: \mathcal{A} \rightarrow [0, \infty]$  una medida positiva. Se verifican las siguientes propiedades:

(i) Si  $A \subset B$ , entonces  $\mu(A) \leq \mu(B)$ . Si además  $\mu(A) < \infty$ , entonces  $\mu(B \setminus A) = \mu(B) - \mu(A)$ .

(ii)  $\mu(A) + \mu(B) = \mu(A \cup B) + \mu(A \cap B)$ .

(iii) Si  $\{A_n\}_{n \in \mathbb{N}}$  es una familia de elementos de  $\mathcal{A}$ , entonces

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mu(A_n)$$

**Demostración.** Solo se va a demostrar la última propiedad. Dada una familia  $\{A_n\}_{n \in \mathbb{N}}$  de elementos de  $\mathcal{A}$ , se construye otra familia  $\{B_n\}_{n \in \mathbb{N}}$ , donde  $B_n = A_n \setminus A_{n-1}$  para cada  $n \geq 2$  y  $B_1 = A_1$ . Se tiene que los  $B_n$  son disjuntos dos a dos, que  $B_n \subset A_n$  para cada  $n \in \mathbb{N}$  y que

$$\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n$$

Consecuentemente,

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \mu\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} \mu(B_n) \leq \sum_{n=1}^{\infty} \mu(A_n),$$

donde se han usado la  $\sigma$ -aditividad y el apartado primero.  $\square$

**Definición 7.** Una medida positiva  $\mu$  en un espacio medible  $(\Omega, \mathcal{A})$  se dice que es **finita** cuando  $\mu(E) < \infty$  para todo  $E \in \mathcal{A}$ , o, equivalentemente, cuando  $\mu(\Omega) < \infty$ .

**Definición 8.** Una medida positiva finita  $P$  en un espacio medible  $(\Omega, \mathcal{A})$  se dice que es una **medida de probabilidad** cuando  $P(\Omega) = 1$ .

**Ejemplo.** Sea  $\omega \in \Omega$  un elemento fijo de un espacio muestral cualquiera, y considérese la función  $\delta_\omega: \mathcal{A} \rightarrow [0, 1]$  dada por

$$\delta_\omega(A) = \begin{cases} 1 & \text{si } \omega \in A \\ 0 & \text{si } \omega \in A^c \end{cases}$$

Se verifica que  $\delta_\omega$  es una medida de probabilidad en cualquier  $\sigma$ -álgebra  $\mathcal{A}$  sobre  $\Omega$ , y se denomina *delta de Dirac*.

**Ejemplo.** Sea  $\Omega$  un espacio muestral finito. Se considera la función  $\mu: \mathcal{A} \rightarrow [0, 1]$  dada por

$$\mu(A) = \frac{\#A}{\#\Omega}$$

Resulta que  $\mu$  es una medida de probabilidad en cualquier  $\sigma$ -álgebra  $\mathcal{A}$  sobre  $\Omega$ , denominada *medida uniforme*.

**Ejemplo.** Sea  $\Omega$  un espacio muestral numerable y sea  $\mathcal{A} = \mathcal{P}(\Omega)$ . Sea  $\{p_w\}_{w \in \Omega}$  una sucesión de números reales no negativos. Se define la función  $\mu: \mathcal{A} \rightarrow [0, \infty]$  mediante

$$\mu(A) = \sum_{\omega \in A} p_\omega$$

Se verifica que  $\mu$  es una medida positiva, pero podría no ser de probabilidad. Cuando se tenga  $p_w = 1$  para todo  $w \in \Omega$ , se dirá que  $\mu$  es la *medida de conteo*.

**Definición 9.** Sea  $\mathcal{A}$  una  $\sigma$ -álgebra sobre  $\Omega$  y sea  $P$  una medida de probabilidad definida sobre  $\mathcal{A}$ . La terna  $(\Omega, \mathcal{A}, P)$  se dice que es un **espacio de probabilidad**.

# Funciones de distribución

## 2.1. Nociones básicas

**Definición 10.** Una función  $F: \mathbb{R} \rightarrow [0, 1]$  se dice que es una **función de distribución** si

- (i) Es monótona creciente.
- (ii) Es continua por la derecha.
- (iii)  $F(-\infty) \equiv \lim_{x \rightarrow -\infty} F(x) = 0$ .
- (iv)  $F(+\infty) \equiv \lim_{x \rightarrow +\infty} F(x) = 1$ .
- (v) Existe  $F(a^-) \equiv \lim_{x \rightarrow a^-} F(x)$  para todo  $a \in \mathbb{R}$ .

**Proposición 4.** Si  $P$  es una medida de probabilidad en el espacio medible-Borel  $(\mathbb{R}, \mathcal{B})$ , entonces la función  $F: \mathbb{R} \rightarrow [0, 1]$  dada por  $F(x) = P((-\infty, x])$  es una función de distribución.

**Demostración.** Ya se vio en la asignatura *Introducción a la Probabilidad y a la Estadística*. □

**Definición 11.** Dada una medida de probabilidad  $P$  en  $(\mathbb{R}, \mathcal{B})$ , la función de distribución definida en la proposición anterior se denomina **función de distribución asociada a  $P$** .

**Proposición 5.** Sea  $F: \mathbb{R} \rightarrow [0, 1]$  la función de distribución asociada a una medida de probabilidad  $P$ . Para cada  $a \in \mathbb{R}$ , se verifican las siguientes propiedades:

- (i)  $P((-\infty, a)) = F(a^-)$ .
- (ii)  $P((a, +\infty)) = 1 - F(a)$ .
- (iii)  $P([a, +\infty)) = 1 - F(a^-)$ .
- (iv)  $p(a) \equiv P(\{a\}) = F(a) - F(a^-)$ .
- (v)  $F$  es continua en  $a$  si y solo si  $p(a) = 0$ .

**Demostración.** Ya se vio en la asignatura *Introducción a la Probabilidad y a la Estadística*. □

Obsérvese que el apartado quinto de la proposición anterior permite escribir el conjunto de puntos de discontinuidad de una función de distribución  $F$  asociada a una medida de probabilidad como

$$D_F := \{x \in \mathbb{R} : p(x) > 0\}$$

**Proposición 6.** Dada una función de distribución  $F$  asociada a una medida de probabilidad, el conjunto  $D_F$  es finito o infinito numerable.

**Demostración.** Sea  $x \in D_F$ . Entonces se tiene que  $F(x^-) < F(x)$ , y por la densidad de  $\mathbb{Q}$  en  $\mathbb{R}$ , existe  $q_x \in \mathbb{Q}$  tal que  $F(x^-) < q_x < F(x)$ . Sea  $y \in D_F$  con  $y \neq x$  y veamos que  $q_y \neq q_x$ . Usando que  $x, y \in D_F$  y que  $F$  es creciente, se tiene que  $F(x^-) < q_x < F(x) \leq F(y^-) < q_y < F(y)$ , así que es claro que  $q_x \neq q_y$ . En consecuencia, la función dada por  $x \mapsto q_x$  es inyectiva, y como  $\mathbb{Q}$  es numerable, entonces  $D_F$  también lo es. □

**Corolario 1.** El conjunto de puntos de continuidad de una función de distribución  $F$  asociada a una medida de probabilidad es denso en  $\mathbb{R}$ .

**Demostración.** Sea  $C_F$  el conjunto de puntos de continuidad de  $F$ . Hay que demostrar que todo abierto no vacío de  $\mathbb{R}$  interseca a  $C_F$ . Sea  $I$  un abierto no vacío de  $\mathbb{R}$ . Como  $D_F$  es numerable e  $I$  es no numerable, entonces  $I \setminus D_F = I \cap D_F^c = I \cap C_F$  es no numerable, luego  $I \cap C_F \neq \emptyset$  y por tanto  $C_F$  es denso en  $\mathbb{R}$ .  $\square$

**Definición 12.** Dada una función de distribución  $F$  asociada a una medida de probabilidad  $P$ , el **soporte de  $F$**  se define como

$$S_F = \{x \in \mathbb{R} : F(x + \varepsilon) - F(x - \varepsilon) > 0 \text{ para todo } \varepsilon > 0\}$$

Nótese que un punto no se encuentra en el soporte de  $F$  si y solo si  $F$  es constante en algún entorno de dicho punto, lo que permite calcular fácilmente  $S_F$  observando la gráfica de  $F$ .

## 2.2. Funciones de distribución discretas

**Definición 13.** Una función de distribución  $F$  asociada a una medida de probabilidad  $P$  se dice que es **discreta** cuando

$$\sum_{x \in \mathbb{R}} p(x) = 1$$

**Proposición 7.** Sea  $F$  una función de distribución discreta asociada a una medida de probabilidad  $P$ . Se verifican las siguientes propiedades:

- (i)  $P(D_F) = 1$ .
- (ii)  $S_F = D_F$ .
- (iii) Si  $B \in \mathcal{B}$ , entonces

$$P(B) = \sum_{x \in D_F \cap B} p(x)$$

**Demostración.** Ejercicio.  $\square$

## 2.3. Funciones de distribución continuas

**Definición 14.** Una función de distribución  $F$  asociada a una medida de probabilidad  $P$  se dice que es **continua** cuando

$$\sum_{x \in \mathbb{R}} p(x) = 0$$

**Definición 15.** Sea  $F$  una función de distribución continua asociada a una medida de probabilidad  $P$ . La **función de pseudodensidad de  $F$**  es la función  $\tilde{f} : \mathbb{R} \rightarrow \mathbb{R}$  definida por

$$\tilde{f}(x) = \begin{cases} F'(x) & \text{si } x \in A \\ 0 & \text{si } x \in A^c, \end{cases}$$

donde  $A$  es el conjunto de puntos donde  $F$  es derivable.

**Proposición 8.** Sea  $F$  una función de distribución continua asociada a una medida de probabilidad  $P$  y con función de pseudodensidad  $\tilde{f}$ . Se verifican las siguientes propiedades:

- (i)  $D_F = \emptyset$ .
- (ii)  $S_F = \{x \in \mathbb{R} : \tilde{f}(x) > 0\} \cup A^c$ .
- (iii) Si  $A^c$  es numerable y  $\tilde{f}$  es integrable, entonces, dado  $B \in \mathcal{B}$ ,

$$P(B) = \int_B \tilde{f}(t) dt$$



**Demostración.** Otro ejercicio. □

## 2.4. Funciones de distribución absolutamente continuas

**Definición 16.** Una función de distribución  $F$  asociada a una medida de probabilidad  $P$  se dice que es **absolutamente continua** cuando existe una función  $f: \mathbb{R} \rightarrow \mathbb{R}$  integrable y no negativa tal que

$$F(x) = \int_{-\infty}^x f(t)dt$$

Esta función  $f$  se denomina **función de densidad de  $F$** .

**Proposición 9.** *Considérese una función de distribución absolutamente continua  $F$  asociada a una medida de probabilidad  $P$  y con función de densidad  $f$ . Se verifican las siguientes propiedades:*

- (i)  $D_F = \emptyset$ .
- (ii)  $S_F = \{x \in \mathbb{R} : f(x) > 0\}$ .
- (iii) Si  $B \in \mathcal{B}$ , entonces

$$P(B) = \int_B f(t)dt$$

**Demostración.** Más ejercicios. □

## 2.5. Funciones de distribución mixtas

**Definición 17.** Una función de distribución  $F$  asociada a una medida de probabilidad  $P$  se dice que es **mixta** cuando

$$0 < \sum_{x \in \mathbb{R}} p(x) < 1$$

**Teorema 1.** *Toda función de distribución  $F$  admite una descomposición de la forma*

$$F = \alpha F_d + (1 - \alpha) F_c,$$

donde  $\alpha \in [0, 1]$ ,  $F_d$  es una función de distribución discreta y  $F_c$  una continua.

**Demostración.** Se define

$$\alpha = \sum_{x \in D_F} p(x)$$

Si fuese  $\alpha = 0$  o  $\alpha = 1$ ,  $F$  sería continua o discreta (respectivamente) y la descomposición sale gratis. Se supone entonces que  $0 < \alpha < 1$ . Sea  $G: \mathbb{R} \rightarrow [0, 1]$  la función definida por

$$G(x) = \frac{1}{\alpha} \sum_{\substack{t \in D_F \\ t \leq x}} p(t)$$

Es fácil comprobar que  $G$  es una función de distribución, y además cumple

$$\sum_{x \in \mathbb{R}} (G(x) - G(x^-)) = \sum_{x \in \mathbb{R}} \frac{1}{\alpha} \left( \sum_{\substack{t \in D_F \\ t \leq x}} p(t) - \sum_{\substack{t \in D_F \\ t < x}} p(t) \right) = \frac{1}{\alpha} \sum_{x \in \mathbb{R}} p(x) = \frac{1}{\alpha} \alpha = 1,$$

luego  $G$  es una función de distribución discreta. Se define también la función  $H: \mathbb{R} \rightarrow [0, 1]$  mediante

$$H(x) = \frac{F(x) - \alpha G(x)}{1 - \alpha}$$

Es claro que  $H$  es función de distribución y que  $F(x) = \alpha G(x) + (1 - \alpha)H(x)$ . Además,

$$F(x) - \alpha G(x) - (F(x^-) - \alpha G(x^-)) = F(x) - F(x^-) - \alpha(G(x) - G(x^-)) = p(x) - \alpha \frac{1}{\alpha} p(x) = 0,$$

de donde se deduce que  $H(x) - H(x^-) = 0$ , y por tanto  $H$  es continua.  $\square$

**Proposición 10.** Sea  $F$  una función de distribución mixta asociada a una medida de probabilidad  $P$ . Se verifican las siguientes propiedades:

(i)  $P(D_F) + P(S_F) = 1$ .

(ii) Si  $B \in \mathcal{B}$ , entonces

$$P(B) = \sum_{x \in D_F \cap B} p(x) + \int_B \tilde{f}(t) dt,$$

siempre que  $F_c$  sea derivable salvo en un conjunto a lo sumo numerable y siempre que la función de pseudodensidad de  $F_c$  sea integrable.

**Demostración.** Tampoco se va a demostrar.  $\square$

**Ejemplo.** Sea  $F: \mathbb{R} \rightarrow [0, 1]$  la función de distribución definida por

$$F(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{x^2}{16} & \text{si } 0 \leq x < 2 \\ \frac{1}{4} & \text{si } 2 \leq x < 4 \\ \frac{x}{4} - \frac{5}{8} & \text{si } 4 \leq x < 5 \\ 1 - \frac{5}{4x} & \text{si } x \geq 5 \end{cases}$$

Se tratará de realizar la descomposición del teorema anterior. En primer lugar, se tiene que

$$D_F = \{4, 5\}, \quad p(4) = \left(\frac{4}{4} - \frac{5}{8}\right) - \frac{1}{4} = \frac{1}{8} \quad \text{y} \quad p(5) = \frac{1}{8},$$

así que  $\alpha = \frac{1}{4}$ . La parte discreta viene dada por

$$G(x) = \begin{cases} 0 & \text{si } x < 4 \\ \frac{1}{\alpha} p(4) & \text{si } 4 \leq x < 5 \\ \frac{1}{\alpha} (p(4) + p(5)) & \text{si } 5 \leq x \end{cases} = \begin{cases} 0 & \text{si } x < 4 \\ \frac{1}{2} & \text{si } 4 \leq x < 5 \\ 1 & \text{si } 5 \leq x \end{cases}$$

La parte continua sería

$$H(x) = \frac{4}{3} (F(x) - \frac{1}{4} G(x)) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{x^2}{12} & \text{si } 0 \leq x < 2 \\ \frac{1}{3} & \text{si } 2 \leq x < 4 \\ \frac{x}{3} - 1 & \text{si } 4 \leq x < 5 \\ 1 - \frac{5}{3x} & \text{si } 5 \leq x \end{cases}$$

# Variables aleatorias

## 3.1. Nociones básicas

**Definición 18.** Sean  $(X, \mathcal{M}_X)$  e  $(Y, \mathcal{M}_Y)$  dos espacios medibles. Una función  $f: X \rightarrow Y$  se dice que es **medible con respecto a  $\mathcal{M}_X$  y  $\mathcal{M}_Y$**  (o simplemente **medible**) si  $f^{-1}(B) \in \mathcal{M}_X$  para todo  $B \in \mathcal{M}_Y$ . Si  $(X, \tau_X)$  y  $(Y, \tau_Y)$  son espacios topológicos, se dirá que  $f$  es una **función de Borel** o que  $f$  es **medible-Borel** si es medible con respecto a  $\mathcal{B}(X)$  y  $\mathcal{B}(Y)$ .

**Definición 19.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad. Una **variable aleatoria con respecto a  $\mathcal{A}$**  (o simplemente **variable aleatoria**) es una función  $X: \Omega \rightarrow \mathbb{R}$  medible, es decir, tal que  $X^{-1}(B) \in \mathcal{A}$  para cada  $B \in \mathcal{B}$ .

**Definición 20.** Dada una variable aleatoria  $X: \Omega \rightarrow \mathbb{R}$  en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ , la **medida de probabilidad inducida por  $X$**  no es más que la función  $P_X: \mathcal{B} \rightarrow [0, 1]$  definida por  $P_X(B) = P(X^{-1}(B))$  para cada  $B \in \mathcal{B}$ .

**Definición 21.** Dada una variable aleatoria  $X: \Omega \rightarrow \mathbb{R}$  en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ , la **función de distribución asociada a  $X$**  no es más que la función  $F_X: \mathbb{R} \rightarrow [0, 1]$  definida mediante  $F_X(a) = P_X((-\infty, a]) = P(X^{-1}((-\infty, a]))$  para cada  $a \in \mathbb{R}$ .

**Definición 22.** Sea  $X$  una variable aleatoria y sea  $F$  la función de distribución asociada a  $X$ . El conjunto  $D_{F_X} = \{x \in \mathbb{R}: p(x) > 0\}$ , también denotado por  $D_X$ , se denomina **rango de  $X$** .

En lugar de  $P_X((-\infty, a])$ , a veces se utiliza la notación  $P(X \leq a)$ . En el caso de  $P_X(\{a\})$ , también se escribe  $P(X = a)$ , y en general, será habitual escribir  $P(X \in B)$  en lugar de  $P_X(B)$ .

**Definición 23.** Sea  $X: \Omega \rightarrow \mathbb{R}$  una variable aleatoria en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ .

- (i) Se dice que  $X$  es **discreta** cuando  $F_X$  lo es.
- (ii) Se dice que  $X$  es **continua** cuando  $F_X$  lo es.
- (iii) Se dice que  $X$  es **mixta** cuando  $F_X$  lo es.
- (iv) Se dice que  $X$  es **absolutamente continua** cuando  $F_X$  lo es, es decir, cuando existe una función  $f_X: \mathbb{R} \rightarrow \mathbb{R}$  integrable y no negativa tal que

$$F_X(a) = \int_{-\infty}^a f_X(t) dt$$

De  $f_X$  se dirá que es la **función de densidad de  $X$** .

En cuanto a las variables aleatorias discretas, lo más natural habría sido definir las como aquellas que toman un número finito o infinito numerable de valores. ¿Será esto equivalente a la definición que se ha dado en la página anterior?

Supóngase que  $X$  toma un conjunto infinito numerable de valores distintos, llámense  $\{x_i\}_{i=1}^{\infty}$  (en el caso

finito se razona igual). Entonces

$$\sum_{x \in \mathbb{R}} p(x) = \sum_{i=1}^{\infty} p(x_i) = \sum_{i=1}^{\infty} P_X(\{x_i\}) = \sum_{i=1}^{\infty} P(X^{-1}(\{x_i\})) = P\left(\bigcup_{i=1}^{\infty} X^{-1}(\{x_i\})\right) = P(\Omega) = 1,$$

luego la función de distribución asociada a  $X$  es discreta. Para tratar de probar el recíproco, supóngase que

$$\sum_{x \in \mathbb{R}} p(x) = 1$$

Es bien sabido que el conjunto  $D(F_X) = \{x \in \mathbb{R} : p(x) > 0\}$  es finito o infinito numerable. Se va a suponer que es infinito numerable (el caso finito se razona igual) y se va a considerar una enumeración  $\{x_i\}_{i=1}^{\infty}$  de los elementos de  $D(F_X)$  (lo que quiere decir que todos los  $x_i$  son distintos). Entonces

$$\sum_{x \in \mathbb{R}} p(x) = \sum_{x \in D(F_X)} p(x) = \sum_{i=1}^{\infty} p(x_i) = P\left(X^{-1}\left(\bigcup_{i=1}^{\infty} \{x_i\}\right)\right) = 1 = P(\Omega),$$

pero esto no implica que se tenga la igualdad

$$\Omega \stackrel{(*)}{=} X^{-1}\left(\bigcup_{i=1}^{\infty} \{x_i\}\right)$$

Sin embargo, lo que sí puede afirmarse es que  $\Omega$  y  $X^{-1}(\bigcup_{i=1}^{\infty} \{x_i\})$  se diferencian en un conjunto de probabilidad cero. Desde el punto de vista probabilístico, estos conjuntos van a ignorarse por completo, y como el rigor matemático en esta asignatura se suele tomar por el pito del sereno, puede afirmarse sin temor alguno que *una variable aleatoria  $X$  toma un número finito o infinito numerable de valores si y solo si  $F_X$  es una función de distribución discreta.*

**Ejemplo.** Sea  $\Omega = \{w_1, w_2, w_3, w_4\}$  un espacio muestral cualquiera y sea  $A = \{w_1, w_2\}$ . Se considera la  $\sigma$ -álgebra  $\mathcal{A} = \{\Omega, \emptyset, A, A^c\}$  sobre  $\Omega$  y se define la variable aleatoria  $X : \Omega \rightarrow \mathbb{R}$  mediante

$$X(w_1) = X(w_2) = -1, \quad X(w_3) = X(w_4) = 1$$

Veamos que, en efecto,  $X$  es una variable aleatoria. Se recuerda que  $\mathcal{B}$  es la  $\sigma$ -álgebra generada por el conjunto

$$E = \{(-\infty, x] : x \in \mathbb{R}\}$$

Por tanto, será suficiente demostrar que para todo  $a \in \mathbb{R}$  se verifica que  $X^{-1}((-\infty, a]) \in \mathcal{A}$ . Tomamos  $a \in \mathbb{R}$ .

- (i) Si  $a < -1$ , entonces  $X^{-1}((-\infty, a]) = \emptyset$ , que está en  $\mathcal{A}$  por ser  $\sigma$ -álgebra.
- (ii) Si  $-1 \leq a < 1$ , entonces  $X^{-1}((-\infty, a]) = \{w_1, w_2\} = A$ , que está en  $\mathcal{A}$  por cómo se ha definido.
- (iii) Si  $1 \leq a$ , entonces  $X^{-1}((-\infty, a]) = \{w_1, w_2, w_3, w_4\} = \Omega$ , que está en  $\mathcal{A}$  por ser  $\sigma$ -álgebra.

Ya puede afirmarse con valentía que  $X$  es una variable aleatoria.

**Ejemplo.** Sean  $\Omega = [0, 4]$ ,  $\mathcal{A} = [0, 4] \cap \mathcal{B}$ . Se define la función  $X : \Omega \rightarrow \mathbb{R}$  mediante

$$X(\omega) = \begin{cases} \omega + 1 & \text{si } 0 \leq \omega < 2 \\ 2 & \text{si } 2 \leq \omega < 3 \\ 9 - 2\omega & \text{si } 3 \leq \omega \leq 4 \end{cases}$$


Se tratará de ver que  $X$  es variable aleatoria. Sea  $a \in \mathbb{R}$ .

- (i) Si  $a < 1$ , entonces  $X^{-1}((-\infty, a]) = \emptyset \in \mathcal{A}$ .
- (ii) Si  $1 \leq a < 2$ , entonces  $X^{-1}((-\infty, a]) = [0, a - 1] \cup [\frac{9-a}{2}, 4] \in \mathcal{A}$ .

(iii) Si  $2 \leq a < 3$ , entonces  $X^{-1}((-\infty, a]) = [0, a-1] \cup [2, 3] \cup [\frac{9-a}{2}, 4] \in \mathcal{A}$ .

(iv) Si  $3 \leq a$ , entonces  $X^{-1}((-\infty, a]) = [0, 4] \in \mathcal{A}$ .


Por tanto,  $X$  es variable aleatoria. Su gráfica es



Si se considera ahora la medida de probabilidad dada por  $P(A) = \frac{1}{4}l(A)$ , con  $l(A)$  la longitud de  $A$ , la función de distribución asociada a la variable aleatoria  $X$  vendría dada por

$$F_X(a) = \begin{cases} 0 & \text{si } a < 1 \\ \frac{3a-3}{8} & \text{si } 1 \leq a < 2 \\ \frac{3a-1}{8} & \text{si } 2 \leq a < 3 \\ 1 & \text{si } a \geq 3 \end{cases}$$


La gráfica de  $F_X$  sería



**Ejemplo.** Sea  $\Omega = \mathbb{R}_+$ , sea  $\mathcal{A} = \mathcal{B} \cap \mathbb{R}_+$  y, para cierto  $\lambda > 0$ , sea  $P: \mathcal{A} \rightarrow [0,1]$  la función definida mediante  $P([0, \omega]) = P([0, \omega)) = 1 - e^{-\lambda\omega}$ . Se considera la variable aleatoria  $X: \Omega \rightarrow \mathbb{R}$  dada por

$$X(\omega) = \begin{cases} 3(3\omega - 1) & \text{si } 0 \leq \omega < \frac{1}{3} \\ 0 & \text{si } \frac{1}{3} \leq \omega < 2 \\ 1 & \text{si } 2 \leq \omega < 3 \\ 3 & \text{si } 3 \leq \omega \end{cases}$$

Se tratará de construir la función de distribución  $F_X$ . La gráfica de  $X$  es



Sea  $a \in \mathbb{R}$ .

- (i) Si  $a < -3$ , entonces  $X^{-1}((-\infty, a]) = \emptyset$ , luego  $F_X(a) = 0$ .
- (ii) Si  $-3 \leq a < 0$ , entonces  $X^{-1}((-\infty, a]) = [0, \frac{a+3}{9}]$ , luego  $F_X(a) = 1 - e^{-\lambda(\frac{a+3}{9})}$ .
- (iii) Si  $0 \leq a < 1$ , entonces  $X^{-1}((-\infty, a]) = [0, 2)$ , luego  $F_X(a) = 1 - e^{-2\lambda}$ .
- (iv) Si  $1 \leq a < 3$ , entonces  $X^{-1}((-\infty, a]) = [0, 3)$ , luego  $F_X(a) = 1 - e^{-3\lambda}$ .
- (v) Si  $3 \leq a$ , entonces  $F_X(a) = 1$ .

En resumidas cuentas,

$$F_X(a) = \begin{cases} 0 & \text{si } a < -3 \\ 1 - e^{-\lambda(\frac{a+3}{9})} & \text{si } -3 \leq a < 0 \\ 1 - e^{-2\lambda} & \text{si } 0 \leq a < 1 \\ 1 - e^{-3\lambda} & \text{si } 1 \leq a < 3 \\ 1 & \text{si } 3 \leq a \end{cases}$$

**Ejemplo.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y sea  $X: \Omega \rightarrow \mathbb{R}$  una variable aleatoria discreta cuyos valores son todos los números naturales. Supóngase que la medida de probabilidad inducida por la variable aleatoria  $X$  viene dada por  $P(X^{-1}(\{n\})) \equiv P(X = n) = p(1-p)^{n-1}$  para todo  $n \in \mathbb{N}$ , siendo  $p \in (0, 1)$  constante. Se define ahora la función  $Y: \Omega \rightarrow \mathbb{R}$  que envía cada  $\omega \in \Omega$  al resto de la división entera  $\frac{X}{3}$ . Es claro que  $Y$  es también una variable aleatoria discreta, y se tiene que

- (i)  $P(Y = 0) = P(X = 3) + P(X = 6) + P(X = 9) + \dots = p[(1-p)^2 + (1-p)^5 + (1-p)^8 + \dots]$ .
- (ii)  $P(Y = 1) = P(X = 1) + P(X = 4) + P(X = 7) + \dots = p[1 + (1-p)^3 + (1-p)^6 + \dots]$ .
- (iii)  $P(Y = 2) = P(X = 2) + P(X = 5) + P(X = 8) + \dots = p[1 - p + (1-p)^4 + (1-p)^7 + \dots]$ .

**Proposición 11.** Sea  $S$  un subconjunto de  $\mathcal{B}$  tal que  $\sigma(S) = \mathcal{B}$ . Una función  $X: \Omega \rightarrow \mathbb{R}$  es una variable aleatoria si y solo si  $X^{-1}(E) \in \mathcal{A}$  para todo  $E \in S$ .

**Demostración.** Una de las implicaciones es trivial. Supóngase que  $X^{-1}(E) \in \mathcal{A}$  para cada  $E \in S$ . Sea  $\mathcal{D} = \{D \in \mathcal{B}: X^{-1}(D) \in \mathcal{A}\}$ . Probar que  $X$  es variable aleatoria es lo mismo que probar que  $\mathcal{D} = \mathcal{B}$ . Se tiene que  $S \subset \mathcal{D} \subset \mathcal{B}$ , luego  $\sigma(S) = \mathcal{B} \subset \sigma(\mathcal{D})$ . Basta demostrar entonces que  $\mathcal{D}$  es  $\sigma$ -álgebra sobre  $\mathbb{R}$ .

- (i)  $\mathbb{R} \in \mathcal{D}$  porque  $X^{-1}(\mathbb{R}) = \Omega \in \mathcal{A}$  al ser  $\mathcal{A}$   $\sigma$ -álgebra.
- (ii) Si  $D \in \mathcal{D}$ , entonces  $X^{-1}(D^c) = X^{-1}(D)^c \in \mathcal{A}$  porque  $X^{-1}(D) \in \mathcal{A}$  y  $\mathcal{A}$  es  $\sigma$ -álgebra. Por tanto,  $D^c \in \mathcal{D}$ .
- (iii) Si  $\{D_i\}_{i \in I}$  es una familia numerable de elementos de  $\mathcal{D}$ , entonces

$$X^{-1}\left(\bigcup_{i \in I} D_i\right) = \bigcup_{i \in I} X^{-1}(D_i)$$

Por definición de  $\mathcal{D}$ , se tiene que  $X^{-1}(D_i) \in \mathcal{A}$  para cada  $i \in I$ , y como  $\mathcal{A}$  es  $\sigma$ -álgebra, la unión de los  $X^{-1}(D_i)$  también es un elemento de  $\mathcal{A}$ . Esto demuestra que

$$\bigcup_{i \in I} D_i \in \mathcal{D}$$

Se concluye que  $\sigma(\mathcal{D}) = \mathcal{D}$ . Por tanto,  $\mathcal{B} \subset \sigma(\mathcal{D}) = \mathcal{D}$ , luego  $\mathcal{D} = \mathcal{B}$  y queda demostrado que  $X$  es variable aleatoria.  $\square$

**Proposición 12.** Sea  $\varphi: \mathbb{R} \rightarrow \mathbb{R}$  una función de Borel y sea  $X: \Omega \rightarrow \mathbb{R}$  una variable aleatoria. Entonces la composición  $\varphi \circ X$  es también una variable aleatoria.

**Demostración.** Sea  $B \in \mathcal{B}$ . Por ser  $\varphi$  medible, se tiene que  $\varphi^{-1}(B) \in \mathcal{B}$ , y como  $X$  es variable aleatoria, entonces  $X^{-1}(\varphi^{-1}(B)) = (\varphi \circ X)^{-1}(B)$ , luego  $\varphi \circ X$  es variable aleatoria.  $\square$

**Ejemplo.** Sea  $X: \Omega \rightarrow \mathbb{R}$  una variable aleatoria y sea  $\varphi: \mathbb{R} \rightarrow \mathbb{R}$  la función definida por  $\varphi(x) = ax + b$ , con  $a > 0$ . Es claro que  $\varphi$  es una función de Borel, luego  $Y = \varphi \circ X$  es variable aleatoria. Además, si  $y \in \mathbb{R}$ ,

$$F_Y(y) = P(Y^{-1}(-\infty, y]) = P(X^{-1}(\varphi^{-1}((-\infty, y]))) = P(X^{-1}(-\infty, \frac{y-b}{a}]) = F_X(\frac{y-b}{a})$$

**Ejemplo.** Sea  $X$  una variable aleatoria absolutamente continua con función de densidad

$$f_X(x) = \begin{cases} e^{-x} & \text{si } x > 0 \\ 0 & \text{en caso contrario} \end{cases}$$

Sea  $Y = [X]$  la variable aleatoria dada por la parte entera de  $X$ . Es fácil comprobar que la parte entera es una función de Borel, implicando que  $Y$  es, efectivamente, una variable aleatoria. Además,

$$(i) \quad P(Y = 0) = P(0 \leq X < 1) = \int_0^1 e^{-x} dx = 1 - \frac{1}{e};$$

$$(ii) \quad P(Y = 1) = P(1 \leq X < 2) = \int_1^2 e^{-x} dx = \frac{1}{e} - \frac{1}{e^2};$$

$$(iii) \quad P(Y = n) = P(n \leq X < n+1) = \int_n^{n+1} e^{-x} dx = \frac{1}{e^n} - \frac{1}{e^{n+1}} \text{ para cada } n \in \mathbb{N}.$$

**Proposición 13.** Sean  $X$  e  $Y$  variables aleatorias en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ . Entonces

(i)  $X + Y$  es una variable aleatoria.

(ii)  $\lambda X$  es una variable aleatoria para todo  $\lambda \in \mathbb{R}$ .

(iii)  $XY$  es una variable aleatoria.

**Demostración.** Ya se vio en la asignatura *Introducción a la Probabilidad y a la Estadística*.  $\square$

**Proposición 14.** Sean  $(\Omega, \tau)$  y  $(\Omega', \tau')$  espacios topológicos y sea  $f: \Omega \rightarrow \Omega'$  una aplicación continua. Entonces  $f$  es medible con respecto a  $\mathcal{B}(\Omega)$  y  $\mathcal{B}(\Omega')$ .

**Demostración.** Como  $\tau'$  genera  $\mathcal{B}(\Omega')$ , basta ver que  $f^{-1}(B) \in \mathcal{B}(\Omega)$  para todo  $B \in \tau'$ . Por ser  $f$  continua y  $B$  abierto, se tiene que  $f^{-1}(B)$  es abierto de  $\tau$ , luego  $f^{-1}(B) \in \sigma(\tau) = \mathcal{B}(\Omega)$ .  $\square$

**Proposición 15.** Sea  $(\Omega, \mathcal{A})$  un espacio medible. Dadas  $n$  funciones  $f_1, f_2, \dots, f_n: \Omega \rightarrow \mathbb{R}$ , se define  $f = (f_1, f_2, \dots, f_n): \Omega \rightarrow \mathbb{R}^n$ . Entonces  $f$  es medible (con respecto a  $\mathcal{A}$  y  $\mathcal{B}_{\mathbb{R}^n}$ ) si y solo si  $f_i$  es medible (con respecto a  $\mathcal{A}$  y  $\mathcal{B}_{\mathbb{R}}$ ) para todo  $i = 1, 2, \dots, n$ .

**Demostración.** Supóngase que  $f$  es medible. Para cada  $i = 1, 2, \dots, n$ , se considera la proyección

$$\begin{aligned} \pi_i: \mathbb{R}^n &\longrightarrow \mathbb{R} \\ (x_1, x_2, \dots, x_n) &\longmapsto x_i \end{aligned}$$

Es claro que  $\pi_i$  es una aplicación continua. Como  $\pi_i$  es medible con respecto a  $\mathcal{B}_{\mathbb{R}^n}$  y  $\mathcal{B}_{\mathbb{R}}$  (usando la proposición anterior), entonces  $\pi_i^{-1}(B) \in \mathcal{B}_{\mathbb{R}^n}$ , y como  $f$  es medible con respecto a  $\mathcal{A}$  y  $\mathcal{B}_{\mathbb{R}^n}$  (por hipótesis), entonces  $f^{-1}(\pi_i^{-1}(B)) = (\pi_i \circ f)^{-1}(B) = f_i^{-1}(B) \in \mathcal{A}$ . Por tanto,  $f_i^{-1}$  es medible.

Supóngase ahora que  $f_i$  es medible para cada  $i = 1, 2, \dots, n$ . Basta ver que  $f^{-1}((-\infty, b]) \in \mathcal{A}$  para cada  $b = (b_1, b_2, \dots, b_n) \in \mathbb{R}^n$ , siendo

$$(-\infty, b] = (-\infty, b_1] \times (-\infty, b_2] \times \dots \times (-\infty, b_n]$$

En efecto, es fácil probar que

$$f^{-1}((-\infty, b]) = \bigcap_{i=1}^{\infty} f_i^{-1}((-\infty, b_i]),$$

de donde se deduce que  $f^{-1}((-\infty, b]) \in \mathcal{A}$  por ser intersección numerable de elementos de  $\mathcal{A}$ .  $\square$

### 3.2. Variables aleatorias simples

**Definición 24.** Sea  $X$  una variable aleatoria en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ . Se dice que  $X$  es **simple** si toma un número finito de valores, en cuyo caso se puede escribir

$$X(\omega) = \sum_{i=1}^n \alpha_i \mathbb{1}_{A_i}(\omega),$$

donde los  $\alpha_i$  son los valores que toma  $X$ ,  $\mathbb{1}$  es la función indicadora y  $A_i = X^{-1}(\{\alpha_i\})$  para cada  $i = 1, \dots, n$ . Dicha representación es denominada **representación canónica de  $X$** .

**Ejemplo.** Considérese el experimento consistente en el lanzamiento de 3 monedas, proporcionando el espacio muestral siguiente:

$$\Omega = \{CCC, CCF, CFC, FCC, CFF, FCF, FFC, FFF\}$$

Sea  $X$  la variable aleatoria que toma como valores el número de caras en cada lanzamiento y defínanse los conjuntos

- (i)  $A_1 = X^{-1}(\{0\}) = \{CCC\}.$
- (ii)  $A_2 = X^{-1}(\{1\}) = \{CCF, CFC, FCC\}.$
- (iii)  $A_3 = X^{-1}(\{2\}) = \{CFF, FCF, FFC\}.$
- (iv)  $A_4 = X^{-1}(\{3\}) = \{FFF\}.$

La representación canónica de  $X$  es

$$X(\omega) = 0 \cdot \mathbb{1}_{A_1}(\omega) + 1 \cdot \mathbb{1}_{A_2}(\omega) + 2 \cdot \mathbb{1}_{A_3}(\omega) + 3 \cdot \mathbb{1}_{A_4}(\omega)$$

**Definición 25.** Dado un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ , una **partición de  $\Omega$**  no es más que una familia numerable  $\mathcal{D} = \{D_i\}_{i \in I}$  de elementos de  $\mathcal{A}$  tales que  $D_i \cap D_j = \emptyset$  para todo  $i \neq j$  y

$$\bigcup_{i \in I} D_i = \Omega$$

**Proposición 16.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y sea  $\mathcal{D} = \{D_i\}_{i=1}^{\infty}$  una partición de  $\Omega$ . Entonces  $X: \Omega \rightarrow \mathbb{R}$  es una variable aleatoria con respecto a  $\sigma(\mathcal{D})$  si y solo si es constante en cada  $D_i$ .

**Demostración.** Supongamos que  $X$  es variable aleatoria. Sea  $n \in \mathbb{N}$  y veamos que  $X$  es constante en  $D_n$ . Sea  $\omega_n \in D_n$  y sea  $x_n = X(\omega_n)$ . Como  $\{x_n\}$  es un cerrado de  $\mathbb{R}$ , entonces  $\{x_n\} \in \mathcal{B}$ , y como  $X$  es variable aleatoria, entonces  $X^{-1}(\{x_n\}) \in \sigma(\mathcal{D})$ . Se sabe que

$$\sigma(\mathcal{D}) = \left\{ \bigcup_{i \in I} D_i : I \subset \mathbb{N} \right\}$$



Por tanto, existe  $I \subset \mathbb{N}$  tal que

$$X^{-1}(\{x_n\}) = \bigcup_{i \in I} D_i$$

Como se tiene que  $\omega_n \in X^{-1}(\{x_n\})$  y  $D_n$  es el único elemento de la partición que contiene a  $\omega_n$ , entonces

$$D_n \subset \bigcup_{i \in I} D_i = X^{-1}(\{x_n\}),$$

luego para todo  $\omega \in D_n$  se verifica  $X(\omega) = X(\omega_n) = x_n$ .

Suponemos ahora que  $X$  es constante  $x_i$  en cada  $D_i$  y veamos que  $X^{-1}(B) \in \sigma(\mathcal{D})$  para cada  $B \in \mathcal{B}$ . Sea  $B \in \mathcal{B}$ . Entonces

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\} = \bigcup_{i=1}^{\infty} \{\omega \in D_i : X(\omega) \in B\}$$

Ahora bien,

$$\{\omega \in D_i : X(\omega) \in B\} = \begin{cases} D_i & \text{si } x_i \in B \\ \emptyset & \text{si } x_i \notin B \end{cases}$$

Se concluye por tanto que  $X^{-1}(B)$  es unión de elementos de  $\sigma(\mathcal{D})$ . □

Obsérvese que  $X$  es constante en cada  $D_i$  si y solo si existe una sucesión de números reales  $\{\alpha_i\}_{i=1}^{\infty}$  de modo que

$$X(\omega) = \sum_{i=1}^{\infty} \alpha_i \mathbb{1}_{D_i}(\omega)$$

para cada  $\omega \in \Omega$ . Aunque no lo parezca, este simple resultado será de cierta utilidad en el futuro.

### 3.3. Cambio de variable

Dada una función de Borel  $\varphi: \mathbb{R} \rightarrow \mathbb{R}$  y una variable aleatoria  $X: \Omega \rightarrow \mathbb{R}$ , es bien sabido que  $Y = \varphi \circ X$  es también una variable aleatoria. Los siguientes resultados, cuyas demostraciones no corresponden a esta asignatura, serán útiles en ciertos casos en los que  $X$  sea absolutamente continua y se quieran hallar las funciones  $P_Y$  o  $f_Y$ .

**Teorema 2 (Teorema del cambio de variable).** *Considérese una variable aleatoria absolutamente continua  $X$  con función de densidad  $f_X$  y sea  $\varphi: I \rightarrow \mathbb{R}$  una función de Borel, estrictamente monótona y con derivada continua. Entonces  $Y = \varphi \circ X$  es una variable aleatoria absolutamente continua cuya función de densidad viene dada por*

$$f_Y(y) = f_X(\varphi^{-1}(y)) |(\varphi^{-1})'(y)|$$

**Teorema 3 (Teorema del cambio de variable generalizado).** *Considérese una variable aleatoria absolutamente continua  $X$  con función de densidad  $f_X$ . Sea  $\{D_i\}_{i=1}^N$  una partición de un intervalo  $I$  y sea  $\varphi: I \rightarrow \mathbb{R}$  una función de Borel tal que  $\varphi|_{D_i}$  es estrictamente monótona y con derivada continua. Entonces  $Y = \varphi \circ X$  es una variable aleatoria absolutamente continua cuya función de densidad viene dada por*

$$f_Y(y) = \sum_{i=1}^N f_X(\varphi_i^{-1}(y)) |(\varphi_i^{-1})'(y)|$$

# Distribuciones de probabilidad usuales

## 4.1. Distribuciones de probabilidad discretas

**Definición 26.** Sea  $X$  una variable aleatoria discreta en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ .

- (i) Dado  $x_0 \in \mathbb{R}$ , se dice que  $X$  sigue una **distribución degenerada en el punto  $x_0$** , y se denota  $X \sim D(x_0)$ , cuando

$$P(X = x) = \begin{cases} 1 & \text{si } x = x_0 \\ 0 & \text{si } x \neq x_0 \end{cases}$$

para cada  $x \in \mathbb{R}$ .

- (ii) Dados  $n$  puntos  $\{x_1, \dots, x_n\}$  distintos, se dice que  $X$  sigue una **distribución uniforme sobre los  $n$  puntos**, y se denota  $X \sim U(\{x_1, \dots, x_n\})$ , cuando

$$P(X = x) = \begin{cases} \frac{1}{n} & \text{si } x \in \{x_1, \dots, x_n\} \\ 0 & \text{si } x \in \{x_1, \dots, x_n\}^c \end{cases}$$

para cada  $x \in \mathbb{R}$ .

- (iii) Dado  $p \in (0, 1)$ , se dice que  $X$  sigue una **distribución de Bernoulli de parámetro  $p$** , y se denota  $X \sim Ber(p)$ , cuando

$$P(X = 0) = 1 - p, \quad P(X = 1) = p \quad \text{y} \quad P(X = x) = 0 \quad \text{en el resto}$$

Usualmente se escribe  $q = 1 - p$ .

- (iv) Dado  $n \in \mathbb{N}$  y dado  $p \in (0, 1)$ , se dice que  $X$  sigue una **distribución binomial de parámetros  $n$  y  $p$** , y se denota  $X \sim Bin(n, p)$ , cuando

$$P(X = k) = \binom{n}{k} p^k q^{n-k} \quad \text{para cada } k \in \mathbb{N} \text{ con } k \leq n, \quad \text{y} \quad P(X = x) = 0 \quad \text{en el resto}$$

- (v) Dado  $p \in (0, 1)$ , se dice que  $X$  sigue una **distribución geométrica de parámetro  $p$** , y se denota  $X \sim Geo(p)$ , cuando

$$P(X = n) = q^n p \quad \text{para cada } n \in \mathbb{N} \cup \{0\}, \quad \text{y} \quad P(X = x) = 0 \quad \text{en el resto}$$

- (vi) Dado  $\lambda > 0$ , se dice que  $X$  sigue una **distribución de Poisson de parámetro  $\lambda$** , y se denota  $X \sim P(\lambda)$ , cuando

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!} \quad \text{para cada } k \in \mathbb{N} \cup \{0\}, \quad \text{y} \quad P(X = x) = 0 \quad \text{en el resto}$$

**Ejemplo.** Dada una variable aleatoria discreta, a cada distribución de probabilidad se le asocia de manera más o menos natural un experimento aleatorio con diversas características:

- (i) Una distribución degenerada está asociada a un experimento aleatorio con un solo resultado, como tirar un dado de una cara.
- (ii) Una distribución uniforme está asociada a un experimento aleatorio con varios resultados de igual probabilidad, como tirar un dado de seis caras.
- (iii) Una distribución de Bernoulli de parámetro  $p \in (0, 1)$  está asociada a un experimento aleatorio con dos posibles resultados. Los valores que toma la variable aleatoria son 0 (*fracaso*, de probabilidad  $q = 1 - p$ ) o 1 (*éxito*, de probabilidad  $p$ ).
- (iv) Una distribución binomial de parámetros  $n \in \mathbb{N}$  y  $p \in (0, 1)$  está asociada a un experimento que consiste en realizar  $n$  pruebas de Bernoulli, todas con probabilidad de éxito  $p$ . Los valores que toma la variable aleatoria son el número de éxitos (o de fracasos).
- (v) Una distribución geométrica de parámetro  $p \in (0, 1)$  está asociada a un experimento aleatorio que consiste en realizar un número indefinido de pruebas de Bernoulli hasta que aparezca el primer éxito, de probabilidad  $p$ . Los valores que toma la variable aleatoria son el número de fracasos antes de conseguir el primer éxito.
- (vi) Una distribución de Poisson de parámetro  $\lambda > 0$  está asociada a un experimento aleatorio que consiste en contar el número de ocurrencias de un fenómeno aleatorio, de frecuencia de ocurrencia media  $\lambda$ , durante un periodo de tiempo fijo o en una región fija del espacio. Los valores que toma la variable aleatoria son el número de ocurrencias por unidad de tiempo o de espacio.

## 4.2. Distribuciones de probabilidad absolutamente continuas

**Definición 27.** Sea  $X$  una variable aleatoria absolutamente continua con función de densidad  $f$  en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ .

- (i) Dado un intervalo  $[a, b] \subset \mathbb{R}$ , se dice que  $X$  sigue una **distribución uniforme en  $[a, b]$** , y se denota  $X \sim U([a, b])$ , cuando

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } x \in [a, b] \\ 0 & \text{en otro caso} \end{cases}$$

- (ii) Dados  $\mu \in \mathbb{R}$  y  $\sigma^2 > 0$ , se dice que  $X$  sigue una **distribución normal de parámetros  $\mu$  y  $\sigma^2$** , y se denota  $X \sim N(\mu, \sigma^2)$ , cuando

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad \text{para cada } x \in \mathbb{R}$$

Cuando  $\mu = 0$  y  $\sigma^2 = 1$ , se habla de **distribución normal estándar**.

- (iii) Dado  $\lambda > 0$ , se dice que  $X$  sigue una **distribución exponencial de parámetro  $\lambda$** , y se denota  $X \sim Exp(\lambda)$ , cuando

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{si } x < 0 \end{cases}$$

# Probabilidad condicionada

## 5.1. Probabilidad condicionada de sucesos

**Definición 28.** Considérese un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ . Dados  $A, B \in \mathcal{A}$  con  $P(B) > 0$ , la **probabilidad condicionada del suceso  $A$  con respecto al suceso  $B$**  se define como

$$P(A|B) := \frac{P(A \cap B)}{P(B)}$$

**Proposición 17.** Siempre que las probabilidades condicionadas tengan sentido, se verifica:

- (i)  $P(A|A) = 1$ .
- (ii)  $P(\emptyset|A) = 0$ .
- (iii) Si  $B \subset A$ , entonces  $P(A|B) = 1$ .
- (iv) Si  $A_1$  y  $A_2$  son disjuntos, entonces  $P(A_1 \cup A_2|B) = P(A_1|B) + P(A_2|B)$ .
- (v)  $P(A|B) + P(A^c|B) = 1$ .

**Demostración.** Bastante inmediata. □

**Proposición 18.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y sea  $B \in \mathcal{A}$  con  $P(B) > 0$ . Entonces  $(\Omega, \mathcal{A}, P(\cdot|B))$  es un espacio de probabilidad, donde

$$\begin{aligned} P(\cdot|B): \mathcal{A} &\longrightarrow [0, 1] \\ A &\longrightarrow P(A|B) \end{aligned}$$

**Demostración.** Es una simple comprobación. □

**Teorema 4 (Teorema de la probabilidad total).** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y sea  $\mathcal{D} = \{D_i\}_{i \in I}$  una partición de  $\Omega$  tal que  $P(D_i) > 0$  con  $i \in I$ . Entonces, dado  $A \in \mathcal{A}$ ,

$$P(A) = \sum_{i \in I} P(A|D_i)P(D_i)$$

**Demostración.** Ya se vio en la asignatura *Introducción a la Probabilidad y a la Estadística*. □

**Teorema 5 (Teorema de Bayes).** Considérese un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$  y sea  $\mathcal{D} = \{D_i\}_{i \in I}$  una partición de  $\Omega$  tal que  $P(D_i) > 0$  para cada  $i \in I$ . Dado  $A \in \mathcal{A}$  con  $P(A) > 0$ , se tiene

$$P(D_i|A) = \frac{P(A|D_i)P(D_i)}{\sum_{j \in I} P(A|D_j)P(D_j)}$$

para todo  $i \in I$ .

**Demostración.** Ya se vio en la asignatura *Introducción a la Probabilidad y a la Estadística*. □

## 5.2. Dependencia e independencia de sucesos

**Definición 29.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad.

(i) Dos sucesos  $A, B \in \mathcal{A}$  son **independientes** cuando

$$P(A \cap B) = P(A)P(B)$$

(ii) Los sucesos de una familia  $\{A_1, A_2, \dots, A_n\} \subset \mathcal{A}$  son **mutuamente independientes** si para toda subcolección finita  $\{A_{i_1}, A_{i_2}, \dots, A_{i_k}\}$ , con  $k \leq n$ , se tiene que

$$P(A_{i_1} \cap A_{i_2} \cap \dots \cap A_{i_k}) = P(A_{i_1})P(A_{i_2}) \dots P(A_{i_k})$$

Por ejemplo, para el caso de tres sucesos  $A_1, A_2$  y  $A_3$ , la independencia mutua requerirá que se verifique

$$P(A \cap B) = P(A)P(B), \quad P(A \cap C) = P(A)P(C), \quad P(B \cap C) = P(B)P(C)$$

$$\text{y } P(A \cap B \cap C) = P(A)P(B)P(C)$$

Evidentemente, la independencia mutua de sucesos implica la independencia a pares, pero el recíproco no es cierto.

**Ejemplo.** Se considera el espacio de probabilidad  $(\Omega, \mathcal{P}(\Omega), P)$ , donde  $\Omega = \{\omega_1, \omega_2, \omega_3, \omega_4\}$  y  $P(\omega_i) = \frac{1}{4}$  para todo  $i = 1, 2, 3, 4$ . Considérense los sucesos  $A = \{\omega_1, \omega_2\}$ ,  $B = \{\omega_1, \omega_3\}$  y  $C = \{\omega_1, \omega_4\}$ . Se tiene que

$$(i) \quad P(A) = \frac{1}{2}$$

$$(iv) \quad P(A \cap B) = \frac{1}{4} = P(A)P(B)$$

$$(ii) \quad P(B) = \frac{1}{2}$$

$$(v) \quad P(A \cap C) = \frac{1}{4} = P(A)P(C)$$

$$(iii) \quad P(C) = \frac{1}{2}$$

$$(vi) \quad P(B \cap C) = \frac{1}{4} = P(B)P(C)$$

Por tanto, los sucesos son independientes dos a dos. Sin embargo,

$$P(A \cap B \cap C) = \frac{1}{4} \neq \frac{1}{8} = P(A)P(B)P(C),$$

luego los sucesos no son mutuamente independientes.

**Ejemplo.** Se considera el espacio  $(\Omega, \mathcal{P}(\Omega), P)$ , con  $\Omega = \{(i, j) \in \mathbb{N}^2 : i, j = 1, 2, 3, 4, 5, 6\}$  y  $P(i, j) = \frac{1}{36}$  para todo  $(i, j) \in \Omega$ . Sean

$$A = \{(i, j) \in \mathbb{N}^2 : j = 1, 2, 5\}, \quad B = \{(i, j) \in \mathbb{N}^2 : j = 4, 5, 6\} \quad \text{y} \quad C = \{(i, j) \in \mathbb{N}^2 : i + j = 9\}$$

Se tiene que

$$(i) \quad P(A) = \frac{1}{2}$$

$$(iv) \quad P(A \cap B) = \frac{1}{6} \neq \frac{1}{4} = P(A)P(B)$$

$$(ii) \quad P(B) = \frac{1}{2}$$

$$(v) \quad P(A \cap C) = \frac{1}{36} \neq \frac{1}{18} = P(A)P(C)$$

$$(iii) \quad P(C) = \frac{1}{9}$$

$$(vi) \quad P(B \cap C) = \frac{1}{12} \neq \frac{1}{18} = P(B)P(C)$$

Por tanto, los sucesos no son independientes dos a dos. Sin embargo,

$$P(A \cap B \cap C) = \frac{1}{36} = P(A)P(B)P(C)$$

Aun así, los sucesos no son mutuamente independientes.

### 5.3. Probabilidad condicionada con respecto a una partición

**Definición 30.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad finito y sea  $\mathcal{D} = \{D_i\}_{i=1}^n$  una partición de  $\Omega$  con  $P(D_i) > 0$  para todo  $i = 1, \dots, n$ . Dado  $A \in \mathcal{A}$ , la **probabilidad condicionada de  $A$  con respecto a la partición  $\mathcal{D}$**  es la función  $P(A|\mathcal{D}): \Omega \rightarrow \mathbb{R}$  definida por

$$P(A|\mathcal{D})(\omega) = \sum_{i=1}^n P(A|D_i) \mathbb{1}_{D_i}(\omega)$$

**Proposición 19.** Se verifican las siguientes propiedades:

- (i)  $P(A|\mathcal{D})$  es una variable aleatoria.
- (ii) Si  $A$  y  $B$  son disjuntos, entonces  $P(A \cup B|\mathcal{D}) = P(A|\mathcal{D}) + P(B|\mathcal{D})$ .

**Demostración.** Bastante inmediata. □

### 5.4. Probabilidad condicionada con respecto a una variable aleatoria

**Definición 31.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad finito y sea  $X: \Omega \rightarrow \mathbb{R}$  una variable aleatoria simple con representación canónica

$$X(\omega) = \sum_{i=1}^n \alpha_i \mathbb{1}_{D_i}(\omega),$$

siendo  $\mathcal{D}_X = \{D_1, \dots, D_n\}$  la partición de  $\Omega$  dada por  $D_i = X^{-1}(\{\alpha_i\})$  para cada  $i = 1, \dots, n$ . Dado  $A \in \mathcal{A}$ , la **probabilidad condicionada de  $A$  con respecto a la variable aleatoria  $X$**  no es más que la probabilidad condicionada de  $A$  con respecto a la partición  $\mathcal{D}_X$ , esto es,

$$P(A|X) := P(A|\mathcal{D}_X)$$

**Ejemplo.** Sean  $X$  e  $Y$  dos variables aleatorias tomando los valores  $\{0, 1\}$  y sea  $p \in (0, 1)$  con

$$P(X=0) = 1-p, \quad P(X=1) = p, \quad P(Y=0) = 1-p \quad \text{y} \quad P(Y=1) = p$$

Se considera la variable aleatoria  $X+Y$ , que toma los valores  $\{0, 1, 2\}$ . Para cada  $k \in \mathbb{N}$ , se tratará de calcular la variable aleatoria  $P((X+Y)^{-1}(\{k\})|Y) \equiv P(X+Y=k|Y)$ . Se define la partición

$$\mathcal{D}_Y = \{Y^{-1}(\{0\}), Y^{-1}(\{1\})\} = \{D_0, D_1\}$$

Que  $Y$  tome los valores 0 y 1 ha provocado la tentación de indexar los elementos de  $\mathcal{D}_Y$  según estos valores y no según el orden, como se hace habitualmente. Se tiene que

$$\begin{aligned} P(X+Y=k|D_0) &\equiv P(X+Y=k|Y=0) = \frac{P(X+Y=k \cap Y=0)}{P(Y=0)} \\ &= \frac{P(X+0=k \cap Y=0)}{P(Y=0)} = \frac{P(X=k)P(Y=0)}{P(Y=0)} = P(X=k) \end{aligned}$$

Se ha utilizado de manera crucial que los sucesos  $X+0=k$  e  $Y=0$  son independientes. De forma análoga se llega a  $P(X+Y=k|D_1) = P(X=k-1)$ , luego

$$\begin{aligned} P(X+Y=k|Y)(\omega) &= P(X+Y=k|D_0) \mathbb{1}_{D_0}(\omega) + P(X+Y=k|D_1) \mathbb{1}_{D_1}(\omega) \\ &= P(X=k) \mathbb{1}_{D_0}(\omega) + P(X=k-1) \mathbb{1}_{D_1}(\omega) \\ &= \begin{cases} (1-p) \mathbb{1}_{D_0}(\omega) & \text{si } k=0 \\ p \mathbb{1}_{D_0}(\omega) + (1-p) \mathbb{1}_{D_1}(\omega) & \text{si } k=1 \\ p \mathbb{1}_{D_1}(\omega) & \text{si } k=2 \end{cases} \end{aligned}$$

¿Son conocidas las variables aleatorias  $\mathbb{1}_{D_0}$  y  $\mathbb{1}_{D_1}$ ? En primer lugar, en cuanto a  $\mathbb{1}_{D_0}$ , se tiene

$$(i) \mathbb{1}_{D_0}(\omega) = 0 \iff Y(\omega) \notin D_0 \iff Y(\omega) \in D_1 \iff Y(\omega) = 1.$$

$$(ii) \mathbb{1}_{D_0}(\omega) = 1 \iff Y(\omega) \in D_0 \iff Y(\omega) = 0.$$

En cuanto a  $\mathbb{1}_{D_1}$ ,

$$(i) \mathbb{1}_{D_1}(\omega) = 0 \iff Y(\omega) \notin D_1 \iff Y(\omega) \in D_0 \iff Y(\omega) = 0.$$

$$(ii) \mathbb{1}_{D_1}(\omega) = 1 \iff Y(\omega) \in D_1 \iff Y(\omega) = 1.$$

Se observa que  $\mathbb{1}_{D_0} = 1 - Y$  y  $\mathbb{1}_{D_1} = Y$ , así que

$$P(X + Y = k | Y) = \begin{cases} (1-p)(1-Y)(\omega) & \text{si } k = 0 \\ p(1-Y)(\omega) + (1-p)Y(\omega) & \text{si } k = 1 \\ pY(\omega) & \text{si } k = 2 \end{cases}$$

## 5.5. Variables aleatorias truncadas

**Definición 32.** Sea  $X$  una variable aleatoria en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$  y sea  $A \in \mathcal{B}$  tal que  $P(X \in A) > 0$ . La **variable aleatoria truncada de  $X$  por  $A$**  no es más que la variable aleatoria  $Y = X|_{X^{-1}(A)}$ , es decir, la función  $Y: X^{-1}(A) \rightarrow \mathbb{R}$  dada por  $Y(\omega) = X(\omega)$ . En este contexto, de  $P_X(A) = P(X \in A)$  se dirá que es el **grado de truncamiento**.

Es importante remarcar que  $Y = X|_{X^{-1}(A)}$  es una variable aleatoria en el espacio de probabilidad  $(X^{-1}(A), \mathcal{A}, \tilde{P})$ , donde

$$\begin{aligned} \tilde{P}: \mathcal{A} &\longrightarrow [0, 1] \\ T &\longmapsto \frac{P(T)}{P(X \in A)} \end{aligned}$$

El motivo por el que la probabilidad de este espacio no puede ser  $P$  es que, generalmente,  $P(X^{-1}(A))$  no es igual a 1, de ahí que haya que «normalizar» la probabilidad para que se tenga  $\tilde{P}(X^{-1}(A)) = 1$ . Por tanto, si  $B \in \mathcal{B}$ , la medida de probabilidad inducida por  $Y$  (que se va a denotar por  $P_Y$  en lugar de  $\tilde{P}_Y$ ) viene dada por

$$\begin{aligned} P_Y(B) &= \tilde{P}(Y^{-1}(B)) = \tilde{P}(\{\omega \in X^{-1}(A): X(\omega) \in B\}) = \tilde{P}(X^{-1}(B) \cap X^{-1}(A)) \\ &= \frac{P(X^{-1}(B) \cap X^{-1}(A))}{P(X^{-1}(A))} = \frac{P_X(B \cap A)}{P_X(A)} = P_X(B|A) \end{aligned}$$

**Ejemplo.** Sea  $X$  una variable aleatoria discreta tomando valores en  $\mathbb{N} \cup \{0\}$ , y considérese el boreliano  $A = [2, \infty) \subset \mathbb{R}$ . Entonces la variable aleatoria truncada  $Y$  de  $X$  por  $A$  toma los valores  $\{2, 3, 4, \dots\}$ , y además

$$P_Y(\{0\}) = P(Y = 0) = \frac{P((X = 0) \cap (X \geq 2))}{P(X \geq 2)} = 0$$

**Ejemplo.** Sea  $X$  una variable aleatoria discreta tal que  $X \sim Ge(p)$  (se recuerda que en este caso  $X$  toma valores en  $\mathbb{N} \cup \{0\}$  y  $P(X = n) = q^n p$ ), y sea  $A = [0, a]$  para cualquier  $a \in \mathbb{N}$ . Entonces la variable aleatoria truncada  $Y$  de  $X$  por  $A$  toma los valores  $\{0, 1, \dots, a\}$ , y además, para cada  $y \in \{0, 1, \dots, a\}$ ,

$$P_Y(\{y\}) = P(Y = y) = \frac{P((X = y) \cap (X \leq a))}{P(X \leq a)} = \frac{P(X = y)}{P(X \leq a)} = \frac{q^y p}{\sum_{i=0}^a q^i p}$$

# Esperanza

## 6.1. Nociones básicas

**Definición 33.** Sea  $X: \Omega \rightarrow \mathbb{R}$  una variable aleatoria. Se define la **esperanza de  $X$**  como

$$E[X] := \int_{\Omega} X(\omega) dP(\omega),$$

siempre que esta integral exista.

La integral anterior es una integral en el sentido de Lebesgue, objeto de estudio de la asignatura *Teoría de la Medida e Integración*. Es por ello que algunas de las demostraciones de esta sección van a omitirse por completo. Por otro lado, es habitual encontrarse las notaciones

$$E[X] = \int_{\Omega} X(\omega) dP(\omega) \equiv \int_{\Omega} X(\omega) P(d\omega) \equiv \int_{\Omega} X dP$$

**Proposición 20.** Dada una variable aleatoria no negativa  $X$ , la esperanza de  $X$  existe si y solo si la integral

$$\int_0^{\infty} (1 - F_X(x)) dx = \int_0^{\infty} P(X > x) dx$$

es finita. Más generalmente, si  $X$  es una variable aleatoria arbitraria, entonces  $E[X]$  existe si y solo si las integrales

$$\int_0^{\infty} (1 - F_X(x)) dx \quad \text{y} \quad \int_{-\infty}^0 F_X(x) dx$$

son finitas, en cuyo caso se tiene

$$E[X] = \int_0^{\infty} (1 - F_X(x)) dx - \int_{-\infty}^0 F_X(x) dx$$

Por motivos de comodidad, si no se hace mención alguna sobre la existencia de cierta esperanza es que se ha supuesto de antemano que dicha esperanza existe.

**Proposición 21.** Se verifican las siguientes propiedades:

- (i) Si  $X$  e  $Y$  son variables aleatorias, entonces  $E[X + Y] = E[X] + E[Y]$ .
- (ii) Si  $a, b \in \mathbb{R}$  y  $X$  es una variable aleatoria, entonces  $E[aX + b] = aE[X] + b$ .
- (iii) Si  $X, Y: \Omega \rightarrow \mathbb{R}$  son variables aleatorias con  $X(\omega) \leq Y(\omega)$  para todo  $\omega \in \Omega$ , entonces  $E[X] \leq E[Y]$ .
- (iv) Si  $g: \mathbb{R} \rightarrow \mathbb{R}$  es medible-Borel y  $X$  es una variable aleatoria, entonces

$$E[g \circ X] = \int_{\mathbb{R}} g(x) dP_X(x)$$



En particular,

$$E[X] = \int_{\mathbb{R}} x dP_X(x)$$

(v) Si  $X$  es una variable aleatoria discreta, entonces

$$E[X] = \sum_{x \in D_X} x P_X(\{x\}) = \sum_{x \in D_X} x P(X = x)$$

(vi) Si  $X$  es una variable aleatoria absolutamente continua con función de densidad  $f$ , entonces

$$E[X] = \int_{\mathbb{R}} x f(x) dx$$

(vii) Si  $X$  es una variable aleatoria mixta, entonces

$$E[X] = \sum_{x \in D_X} x P(X = x) + \int_{\mathbb{R}} x \tilde{f}(x) dx,$$

donde  $\tilde{f}$  es la pseudodensidad de la parte continua de la función de distribución de  $X$ .

(viii) Si  $X$  e  $Y$  son variables aleatorias independientes, entonces  $E[XY] = E[X]E[Y]$ . Si además  $\varphi: \mathbb{R} \rightarrow \mathbb{R}$  es medible-Borel, entonces  $E[\varphi(X)\varphi(Y)] = E[\varphi(X)]E[\varphi(Y)]$ .

## 6.2. Momentos de una variable aleatoria

**Definición 34.** Sea  $X$  una variable aleatoria y sea  $n \in \mathbb{N}$ .

- (i) Se define el **momento de orden  $n$  de  $X$**  como la esperanza de la variable aleatoria  $X^n$ .
- (ii) Se define el **momento centrado de orden  $n$  de  $X$**  como el momento de orden  $n$  de  $X - E[X]$ .
- (iii) Se define la **varianza de  $X$**  como su momento centrado de orden 2, es decir,

$$\text{Var}[X] := E[(X - E[X])^2] = E[X^2] - E[X]^2$$

- (iv) Si  $Y$  es otra variable aleatoria, se define la **covarianza de  $X$  e  $Y$**  como

$$\text{Cov}[X, Y] := E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

Cuando  $\text{Cov}[X, Y] = 0$  se dice que  $X$  e  $Y$  son **incorreladas**.

De la definición anterior se deduce inmediatamente que  $\text{Cov}[X, X] = 0$  y que si  $X$  e  $Y$  son variables aleatorias independientes entonces son incorreladas.

**Ejemplo.** Sea  $X$  una variable aleatoria discreta con  $X \sim \text{Deg}(a)$  para cierto  $a \in \mathbb{R}$ . Entonces

$$E[X] = a \cdot P(X = a) = a, \quad \text{Var}[X] = E[X^2] - E[X]^2 = 0$$

**Ejemplo.** Sea  $X$  una variable aleatoria discreta con  $X \sim \text{Ber}(p)$ , donde  $p \in (0, 1)$ . Entonces

$$E[X] = 0(1 - p) + 1p = p, \quad \text{Var}[X] = p - p^2 = p(1 - p)$$

**Ejemplo.** Sea  $X$  una variable aleatoria discreta con  $X \sim \text{Bin}(n, p)$ , donde  $n \in \mathbb{N}$ ,  $p \in (0, 1)$ . Como  $X$  representa el número de éxitos en  $n$  ensayos de Bernoulli con probabilidad  $p$ , se tiene  $X = X_1 + \dots + X_n$ , donde para cada  $i = 1, \dots, n$ ,  $X_i$  toma los valores 0 o 1 dependiendo de si en el  $i$ -ésimo ensayo hay un fracaso o un éxito. Por tanto,  $X_i \sim \text{Ber}(p)$ , luego

$$E[X] = E[X_1 + \dots + X_n] = E[X_1] + \dots + E[X_n] = p + \dots + p = np$$

Para la varianza, se observa que  $E[X^2] = E[X(X-1)] + E[X]$ , donde

$$\begin{aligned} E[X(X-1)] &= \sum_{k=0}^n k(k-1) \binom{n}{k} p^k q^{n-k} = \sum_{k=2}^n k(k-1) \binom{n}{k} p^k q^{n-k} \\ &= \sum_{k=2}^n \frac{n!}{(k-2)!(n-k)!} p^k q^{n-k} = n(n-1)p^2 \sum_{k=2}^n \binom{n-2}{k-2} p^{k-2} q^{n-k} \\ &= n(n-1)p^2 \sum_{k=0}^{n-2} \binom{n-2}{k} p^k q^{n-k-2} \stackrel{(*)}{=} n(n-1)p^2(p+q)^{n-2} = n(n-1)p^2 \end{aligned}$$

Por tanto,

$$\text{Var}[X] = n(n-1)p^2 + np - n^2p^2 = npq$$

Por si la igualdad (\*) causase incertidumbre, se recuerda que para todos  $x, y \in \mathbb{R}$  y  $n \in \mathbb{N}$  se tiene

$$\sum_{k=0}^n \binom{n}{k} x^k y^{n-k} = (x+y)^n$$

**Ejemplo.** Sea  $X$  una variable aleatoria absolutamente continua con  $X \sim N(\mu, \sigma^2)$  para ciertos  $\mu \in \mathbb{R}$ ,  $\sigma^2 > 0$ . Se tiene que

$$\begin{aligned} E[X] &= \int_{\mathbb{R}} xf(x)dx = \frac{1}{\sigma\sqrt{2\pi}} \int_{\mathbb{R}} xe^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \stackrel{(*)}{=} \frac{\sqrt{2}\sigma}{\sigma\sqrt{2\pi}} \int_{\mathbb{R}} (\sqrt{2}\sigma t + \mu)e^{-t^2} dt \\ &= \frac{1}{\sqrt{\pi}} \left( \sqrt{2}\sigma \int_{\mathbb{R}} te^{-t^2} dt + \mu \int_{\mathbb{R}} e^{-t^2} dt \right) = \frac{1}{\sqrt{\pi}} \left( \sqrt{2}\sigma \left[ -\frac{1}{2}e^{-t^2} \right]_{-\infty}^{+\infty} + \mu\sqrt{\pi} \right) = \frac{\mu\sqrt{\pi}}{\sqrt{\pi}} = \mu, \end{aligned}$$

donde en (\*) se ha hecho  $t = \frac{x-\mu}{\sqrt{2}\sigma}$ ;  $dt = \frac{1}{\sqrt{2}\sigma} dx$ . Cálculos similares demuestran que  $\text{Var}[X] = \sigma^2$ .

**Ejemplo.** Sea  $X$  una variable aleatoria absolutamente continua con  $X \sim \text{Exp}(\lambda)$  para cierto  $\lambda > 0$ . Se tiene que

$$E[X] = \int_{\mathbb{R}} xf(x)dx = \int_0^{\infty} x\lambda e^{-\lambda x} dx$$

Se halla primero la primitiva:

$$\int \lambda x e^{-\lambda x} dx \stackrel{(*)}{=} -xe^{-\lambda x} - \int -e^{-\lambda x} dx = -xe^{-\lambda x} - \frac{1}{\lambda} e^{-\lambda x},$$

donde en (\*) se ha integrado por partes:

$$(*) \left\{ \begin{array}{ll} u(x) = \lambda x; & u'(x) = \lambda \\ v(x) = -\frac{1}{\lambda} e^{-\lambda x}; & v'(x) = e^{-\lambda x} \end{array} \right\}$$

Por tanto,

$$E[X] = \left[ -xe^{-\lambda x} - \frac{1}{\lambda} e^{-\lambda x} \right]_0^{\infty} = \frac{1}{\lambda}$$

Cálculos similares demuestran que

$$\text{Var}[X] = \frac{1}{\lambda^2}$$

**Ejemplo.** Sea  $X$  una variable aleatoria discreta con  $X \sim P(\lambda)$  para cierto  $\lambda > 0$ . Se tiene que

$$E[X] = \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=1}^{\infty} k \frac{\lambda^k}{k!} = e^{-\lambda} \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = e^{-\lambda} \lambda \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} \lambda e^{\lambda} = \lambda$$

Por otro lado,

$$\begin{aligned} E[X(X-1)] &= \sum_{k=0}^n k(k-1)e^{-\lambda} \frac{\lambda^k}{k!} = \sum_{k=2}^{\infty} e^{-\lambda} \frac{\lambda^k}{(k-2)!} = \lambda^2 e^{-\lambda} \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} = \lambda^2 e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} \\ &= \lambda^2 e^{-\lambda} e^{\lambda} = \lambda^2 \end{aligned}$$

Por tanto,

$$\text{Var}[X] = E[X(X-1)] + E[X] - E[X]^2 = \lambda$$

**Proposición 22.** Se verifican las siguientes propiedades:

- (i) Si  $a, b \in \mathbb{R}$  y  $X$  es una variable aleatoria, entonces  $\text{Var}[aX + b] = a^2 \text{Var}[X]$ .
- (ii) Si  $X_1, \dots, X_n$  son variables aleatorias independientes dos a dos, entonces

$$\text{Var}[X_1 + \dots + X_n] = \text{Var}[X_1] + \dots + \text{Var}[X_n]$$

En consecuencia, si  $a_1, \dots, a_n \in \mathbb{R}$ ,

$$\text{Var}[a_1 X_1 + \dots + a_n X_n] = a_1^2 \text{Var}[X_1] + \dots + a_n^2 \text{Var}[X_n],$$

**Demostración.** Solo se va a probar el apartado segundo. Se tiene que

$$\begin{aligned} \text{Var}\left[\sum_{i=1}^n X_i\right] &= E\left[\left(\sum_{i=1}^n X_i - E\left[\sum_{i=1}^n X_i\right]\right)^2\right] \\ &= E\left[\left(\sum_{i=1}^n X_i - \sum_{i=1}^n E[X_i]\right)^2\right] \\ &= E\left[\left(\sum_{i=1}^n (X_i - E[X_i])\right)^2\right] \\ &= E\left[\sum_{i=1}^n (X_i - E[X_i])^2 + 2 \sum_{1 \leq i < j \leq n} E[(X_i - E[X_i])(X_j - E[X_j])]\right] \\ &\stackrel{(*)}{=} E\left[\sum_{i=1}^n (X_i - E[X_i])^2\right] \\ &= \sum_{i=1}^n E[(X_i - E[X_i])^2] \\ &= \sum_{i=1}^n \text{Var}[X_i], \end{aligned}$$

donde en la igualdad (\*) se ha usado que  $E[(X_i - E[X_i])(X_j - E[X_j])] = 0$  gracias a la independencia de las variables.  $\square$

**Proposición 23 (Desigualdad de Markov).** Dada una variable aleatoria no negativa  $X$ , para cada  $t > 0$  se tiene

$$P(X \geq t) \leq \frac{E[X]}{t}$$

**Demostración.** Solo va a demostrarse para variables aleatorias discretas y absolutamente continuas. Si  $X$  toma los valores  $x_k$  con  $k \in \mathbb{N}$  y  $P(X = x_k) = p_k$ , entonces para cada  $t > 0$  se tiene

$$E[X] = \sum_{k=1}^{\infty} x_k p_k \geq \sum_{x_k \geq t} x_k p_k \geq \sum_{x_k \geq t} t p_k = t \cdot P(X \geq t),$$

de donde se deduce la desigualdad del enunciado. Si fuese  $X$  una variable aleatoria absolutamente

continúa disfrutando de una función de densidad  $f$ , entonces

$$E[X] = \int_{\mathbb{R}} xf(x)dx \geq \int_t^{\infty} xf(x)dx \geq \int_t^{\infty} tf(x)dx = t \int_t^{\infty} f(x)dx = t \cdot P(X \geq t),$$

de donde se deduce la desigualdad del enunciado.  $\square$

**Corolario 2 (Desigualdad de Chebyshev).** Si  $X$  es una variable aleatoria con varianza finita, entonces para todo  $\varepsilon > 0$  se verifica

$$P(|X - E[X]| \geq \varepsilon) \leq \frac{\text{Var}[X]}{\varepsilon^2}$$

**Demostración.** Basta aplicar la proposición anterior a la variable aleatoria no negativa  $(X - E[X])^2$  tomando  $t = \varepsilon^2$ :

$$P((X - E[X])^2 \geq \varepsilon^2) \leq \frac{E[(X - E[X])^2]}{\varepsilon^2},$$

de donde se deduce inmediatamente la desigualdad del enunciado.  $\square$

Como caso particular, tomando  $\varepsilon = h\sigma$  para cualquier  $h > 0$ , con  $\sigma = \sqrt{\text{Var}[X]}$ , la desigualdad de Chebyshev dice que

$$P(|X - E[X]| \geq h\sigma) \leq \frac{\text{Var}[X]}{h^2\sigma^2} = \frac{1}{h^2} \quad \text{y} \quad P(|X - E[X]| < h\sigma) \geq 1 - \frac{1}{h^2},$$

lo que permite acotar la probabilidad de que un valor de una variable aleatoria desconocida se encuentre en un intervalo de centro la esperanza y longitud  $2h\sigma$ .

### 6.3. Función generatriz de probabilidad

**Definición 35.** Sea  $X$  una variable aleatoria discreta que toma valores en  $\mathbb{N} \cup \{0\}$ , y sea  $p_n = P(X = n)$  para cada  $n \in \mathbb{N} \cup \{0\}$ . La **función generatriz de probabilidad de  $X$**  es la función dada por

$$G_X(s) = \sum_{n=0}^{\infty} p_n s^n = E[s^X]$$

para cada  $s \in \mathbb{R}$  que consiga que la serie anterior converja.

Obsérvese que la función generatriz siempre tiene sentido en el intervalo  $(-1, 1)$ , pues la serie de los valores absolutos puede acotarse por una serie geométrica de razón  $|s| < 1$ . Además, en  $s = 1$  la serie converge y vale 1.

**Ejemplo.** Supóngase que  $X \sim \text{Bin}(n, p)$  para cierto  $n \in \mathbb{N}$  y  $p \in (0, 1)$ . Entonces, para todo  $s \in \mathbb{R}$ ,

$$G_X(s) = \sum_{k=0}^{\infty} p_k s^k = \sum_{k=0}^n \binom{n}{k} p^k q^{n-k} s^k = (ps + q)^n$$

**Ejemplo.** Supóngase que  $X \sim \text{Ge}(p)$  para cierto  $p \in (0, 1)$ . Entonces

$$G_X(s) = \sum_{n=0}^{\infty} p_n s^n = \sum_{n=0}^{\infty} q^n p s^n = p \sum_{n=0}^{\infty} (sq)^n,$$

luego  $G_X(s)$  existe si y solo si  $|sq| < 1$ , es decir, si y solo si  $|s| < \frac{1}{q}$ , en cuyo caso se tiene

$$G_X(s) = \frac{p}{1 - sq}$$

**Ejemplo.** Supóngase que  $X \sim P(\lambda)$  para cierto  $\lambda > 0$ . Entonces para todo  $s \in \mathbb{R}$  se tiene

$$G_X(s) = \sum_{n=0}^{\infty} e^{-\lambda} \frac{\lambda^n}{n!} s^n = e^{-\lambda} \sum_{n=0}^{\infty} \frac{(\lambda s)^n}{n!} = e^{-\lambda} e^{\lambda s} = e^{\lambda(s-1)}$$

**Proposición 24.** Sean  $X_1, \dots, X_n$  variables aleatorias discretas independientes tomando valores en  $\mathbb{N} \cup \{0\}$  y con funciones generatrices  $G_{X_i}$  para cada  $i = 1, \dots, n$ . Entonces

$$G_{X_1+\dots+X_n}(s) = G_{X_1}(s) \dots G_{X_n}(s)$$

para cada  $s \in \mathbb{R}$  donde estén definidas todas las  $G_{X_i}$ .

**Demostración.** Es una simple comprobación:

$$G_{X_1+\dots+X_n}(s) = E[s^{X_1+\dots+X_n}] = E[s^{X_1} \dots s^{X_n}] \stackrel{(*)}{=} E[s^{X_1}] \dots E[s^{X_n}] = G_{X_1}(s) \dots G_{X_n}(s)$$

En la igualdad (\*) ha sido fundamental que las variables son independientes y que la función dada por  $f(t) = s^t$  para cada  $t \in \mathbb{R}$  es medible-Borel, pues es continua.  $\square$

**Teorema 6 (Fórmula de inversión).** Sea  $X$  una variable aleatoria discreta con valores en  $\mathbb{N} \cup \{0\}$  y función generatriz de probabilidad  $G_X$ . Entonces, para cada  $k \in \mathbb{N} \cup \{0\}$  se tiene

$$p_k = \frac{G_X^{(k)}(0)}{k!}$$

**Demostración.** En primer lugar, por ser  $G_X$  una serie de potencias, entonces es de clase infinito en el interior del intervalo de convergencia  $I$ , y además, para todo  $s \in I$  y  $k \in \mathbb{N}$ , se verifica

$$G_X^{(k)}(s) = \sum_{n=k}^{\infty} p_n n(n-1)(n-2) \dots (n-k+1) s^{n-k} = p_k k! + \sum_{n=k+1}^{\infty} p_n n(n-1)(n-2) \dots (n-k+1) s^{n-k}$$

Evaluando en 0 (obsérvese que  $0 \in (-1, 1) \subset I$ ) se obtiene  $G_X^{(k)}(0) = p_k k!$ , de donde se deduce la fórmula del enunciado.  $\square$

La importancia de esta fórmula reside en el hecho de que la distribución de probabilidad de una variable aleatoria queda totalmente determinada por la función generatriz de probabilidad.

**Ejemplo.** Supóngase que  $X \sim \text{Bin}(n, p)$  e  $Y \sim \text{Bin}(m, p)$  son variables independientes, donde  $m, n \in \mathbb{N}$  y  $p \in (0, 1)$ . Entonces

$$G_{X+Y}(s) = G_X(s)G_Y(s) = (ps + q)^n (ps + q)^m = (ps + q)^{n+m}$$

Como se ha visto que la función generatriz determina completamente la distribución de  $X + Y$ , puede afirmarse que  $X + Y \sim \text{Bin}(n + m, p)$ .

**Ejemplo.** Supóngase que  $X \sim P(\lambda)$  e  $Y \sim P(\mu)$  son variables independientes, donde  $\lambda, \mu > 0$ . Entonces  $X + Y \sim P(\lambda + \mu)$ , ya que

$$G_{X+Y}(s) = G_X(s)G_Y(s) = e^{\lambda(s-1)} e^{\mu(s-1)} = e^{(\lambda+\mu)(s-1)}$$

**Proposición 25.** Sea  $X$  una variable aleatoria discreta tomando valores en  $\mathbb{N} \cup \{0\}$  y con función generatriz de probabilidad  $G_X$ . Se verifican las siguientes propiedades:

- (i)  $E[X] = G'_X(1)$ .
- (ii)  $E[X^2] = G''_X(1) + G'_X(1)$ .
- (iii)  $\text{Var}[X] = G''_X(1) + G'_X(1) - G'_X(1)^2$ .

**Demostración.** Los dos primeros apartados son simples comprobaciones y el tercero es consecuencia inmediata de los anteriores.  $\square$

## 6.4. Función generatriz de momentos

**Definición 36.** Sea  $X$  una variable aleatoria. La **función generatriz de momentos asociada a  $X$**  se define como

$$M_X(t) := E[e^{tX}]$$

para cada  $t \in \mathbb{R}$  donde la esperanza de  $e^{tX}$  exista.

En particular, si  $X$  es una variable aleatoria discreta tomando valores en  $\mathbb{N} \cup 0$ , entonces, recordando que  $G_X(s) = E[s^X]$ , se tiene

$$M_X(t) = G_X(e^t) = \sum_{n=0}^{\infty} e^{tn} P(X = n)$$

Por otro lado, si  $X$  es una variable aleatoria absolutamente continua con función de densidad  $f$ , se verifica

$$M_X(t) = \int_{\mathbb{R}} e^{tx} f(x) dx$$

**Proposición 26.** Se verifican las siguientes propiedades:

(i) Si  $X$  e  $Y$  son variables aleatorias independientes, entonces

$$M_{X+Y}(t) = M_X(t)M_Y(t)$$

para cada  $t \in \mathbb{R}$  donde  $M_X(t)$  y  $M_Y(t)$  tengan sentido.

(ii) Si  $a, b \in \mathbb{R}$  y  $X$  es una variable aleatoria, entonces

$$M_{aX+b}(t) = e^{bt} M_X(at)$$

para cada  $t \in \mathbb{R}$  donde  $M_X(at)$  tenga sentido.

(iii) Si  $X$  es una variable aleatoria y  $k \in \mathbb{N}$ ,

$$M_X^{(k)}(0) = E[X^k]$$

En particular,

$$M_X''(0) - \mu^2 = \sigma^2,$$

donde  $\mu = E[X]$  y  $\sigma^2 = \text{Var}[X]$ .

**Demostración.** La prueba de los dos primeros apartados es inmediata. La del tercero es un poco menos inmediata pero los cálculos son lo suficientemente pesados como para omitir la prueba.  $\square$

## 6.5. Función característica

**Definición 37.** Dada una variable aleatoria  $X$ , la **función característica de  $X$**  es la función  $\varphi_X: \mathbb{R} \rightarrow \mathbb{C}$  dada por

$$\varphi_X(t) = E[e^{itX}]$$

Se recuerda que para todo  $\mu = \alpha + i\beta \in \mathbb{C}$  se tiene que  $e^\mu = e^\alpha(\cos(\beta t) + i \sin(\beta t))$ . Obsérvese además que la integral

$$\int_{\mathbb{R}} e^{itX(\omega)} dP(\omega) = \varphi_X(t)$$

siempre existe, de ahí que se haya tenido la valentía de definir  $\varphi_X$  en todo  $\mathbb{R}$ .

**Proposición 27.** Dada una variable aleatoria  $X$ , se verifican las siguientes propiedades:

- (i)  $\varphi_X(t) = M_X(it)$  para todo  $t \in \mathbb{R}$ .
- (ii)  $|\varphi_X(t)| \leq 1$  para todo  $t \in \mathbb{R}$ .
- (iii)  $\varphi_X(-t) = \overline{\varphi_X(t)}$  para todo  $t \in \mathbb{R}$ .
- (iv)  $\varphi_{aX+b}(t) = e^{itb} \varphi_X(at)$  para todo  $t \in \mathbb{R}$ .
- (v) Si  $\varphi_X(t) \in \mathbb{R}$  para todo  $t \in \mathbb{R}$ , entonces  $\varphi_{-X} = \varphi_X$ .
- (vi) Si existe  $E[X^n]$  para algún  $n \in \mathbb{N}$ , entonces

$$E[X^r] = \frac{\varphi_X^{(r)}(0)}{i^r}$$

para todo  $r \in \mathbb{N}$  con  $r \leq n$ .

**Demostración.** Comprobaciones fáciles e inmediatas. □

## 6.6. Otras características numéricas

Además de la esperanza y la varianza, algunas características numéricas de una variable aleatoria  $X$  que se han estudiado ya en múltiples ocasiones son las *medidas de posición* (la mediana, la moda o los percentiles), y las *medidas de dispersión* (la desviación típica o el coeficiente de variación).

**Definición 38.** Sea  $X$  una variable aleatoria en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ . Un número real  $\text{Me}[X] \in \mathbb{R}$  se dice que es una **mediana de  $X$**  cuando

$$P(X \leq \text{Me}[X]) \geq \frac{1}{2} \quad \text{y} \quad P(X \geq \text{Me}[X]) \geq \frac{1}{2},$$

o, equivalentemente, cuando

$$\frac{1}{2} \leq F_X(\text{Me}[X]) \leq \frac{1}{2} + P(X = \text{Me}[X])$$

**Ejemplo.** Sea  $X$  una variable aleatoria cuya función de distribución viene dada por

$$F(x) = \begin{cases} 0 & \text{si } x < 0 \\ x - \frac{x^2}{2} & \text{si } 0 \leq x < 1 \\ \frac{1}{2} & \text{si } 1 \leq x < 2 \\ \frac{x}{4} & \text{si } 2 \leq x < 4 \\ 1 & \text{si } 4 \leq x \end{cases}$$

Cualquier punto de  $[1, 2]$  es una mediana de  $X$ .

**Definición 39.** Sea  $X$  una variable aleatoria en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ . Dado  $\alpha \in \mathbb{R}$  y  $P_\alpha \in \mathbb{R}$ , se dice que  $P_\alpha$  es un **percentil de orden  $\alpha$**  cuando

$$P(X \leq P_\alpha) \geq \frac{\alpha}{100} \quad \text{y} \quad P(X \geq P_\alpha) \geq 1 - \frac{\alpha}{100}$$

Si  $\alpha \in \{25, 50, 75\}$ , se hablará de **cuartiles**, y si  $\alpha = 10$ , de **deciles**.

**Definición 40.** Sea  $X$  una variable aleatoria en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ .

- (i) Si  $X$  es discreta, se define la **moda de  $X$**  como su valor de mayor probabilidad.
- (ii) Si  $X$  es absolutamente continua, se define la **moda de  $X$**  como el valor máximo de su función de densidad.

**Definición 41.** Sea  $X$  una variable aleatoria en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ . Se define la **desviación típica de  $X$**  como

$$\sigma = \sqrt{\text{Var}[X]},$$

mientras que el **coeficiente de variación de  $X$**  no es más que

$$C_V = \frac{\sigma}{E[X]}$$



# Vectores aleatorios

## 7.1. Nociones básicas

En este tema, la  $\sigma$ -álgebra de Borel de  $\mathbb{R}^n$  junto con la topología usual será denotada por  $\mathcal{B}^n$  en lugar de  $\mathcal{B}(\mathbb{R}^n)$ .

**Definición 42.** Dado un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ , un **vector aleatorio** es una función  $X: \Omega \rightarrow \mathbb{R}^n$  medible con respecto a  $\mathcal{A}$  y  $\mathcal{B}^n$ , es decir, tal que  $X^{-1}(B) \in \mathcal{A}$  para todo  $B \in \mathcal{B}^n$ .

**Proposición 28.** Dado un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ , una función  $X: \Omega \rightarrow \mathbb{R}^n$  es un vector aleatorio si y solo si cada componente  $X_i: \Omega \rightarrow \mathbb{R}$  es una variable aleatoria.

**Demostración.** Consecuencia inmediata de la Proposición 15. □

**Definición 43.** Sea  $X$  un vector aleatorio en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ . La **medida de probabilidad inducida por  $X$**  es la función  $P_X: \mathcal{B}^n \rightarrow [0, 1]$  definida por

$$P_X(B) = P(X^{-1}(B))$$

para cada  $B \in \mathcal{B}^n$ .

**Definición 44.** Sea  $X$  un vector aleatorio en un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ . La **función de distribución conjunta asociada a  $X$**  es la función  $F: \mathbb{R}^n \rightarrow [0, 1]$  definida por

$$F(a_1, \dots, a_n) = P(X_1 \leq a_1, \dots, X_n \leq a_n)$$

para cada  $(a_1, \dots, a_n) \in \mathbb{R}^n$

Respecto a la notación utilizada para referirse a  $F(a_1, \dots, a_n)$ , es habitual encontrarse las expresiones

$$P(X \leq a), \quad P_X((-\infty, a_1] \times \dots \times (-\infty, a_n]) \quad \text{o} \quad P(X_1 \leq a_1 \cap \dots \cap X_n \leq a_n)$$

**Proposición 29.** Sea  $X$  un vector aleatorio con función de distribución conjunta  $F$ . Entonces

(i) Se verifica que

$$F(\infty, \dots, \infty) \equiv \lim_{a_1 \rightarrow \infty, \dots, a_n \rightarrow \infty} F(a_1, \dots, a_n) = 1$$

(ii) Para cada  $i \in \{1, \dots, n\}$  y cada  $(a_1, \dots, a_n) \in \mathbb{R}^n$ ,

$$F(a_1, \dots, a_{i-1}, -\infty, a_{i+1}, \dots, a_n) \equiv \lim_{a_i \rightarrow -\infty} F(a_1, \dots, a_n) = 0$$

(iii)  $F$  es creciente en cada componente.

(iv)  $F$  es continua por la derecha en cada componente.

**Demostración.** Como viene siendo habitual en esta asignatura, se omite la demostración. □

## 7.2. Vectores aleatorios bidimensionales

**Proposición 30.** Sea  $(X, Y)$  un vector aleatorio bidimensional y sea  $F$  su función de distribución conjunta. Entonces

(i) Se verifica que

$$F(\infty, \infty) \equiv \lim_{a_1 \rightarrow \infty, a_2 \rightarrow \infty} F(a_1, a_2) = 1$$

(ii) Para cada  $(x, y) \in \mathbb{R}^2$ ,

$$F(-\infty, y) \equiv \lim_{x \rightarrow -\infty} F(x, y) = 0 \quad y \quad F(x, -\infty) \equiv \lim_{y \rightarrow -\infty} F(x, y) = 0$$

(iii) Si  $y \in \mathbb{R}$ ,

$$F(x, y) \leq F(x', y) \text{ para todos } x, x' \in \mathbb{R} \text{ con } x < x',$$

y si  $x \in \mathbb{R}$ ,

$$F(x, y) \leq F(x, y') \text{ para todos } y, y' \in \mathbb{R} \text{ con } y < y'$$

(iv) Para cada  $(x, y) \in \mathbb{R}$ ,

$$\lim_{h \rightarrow 0^+} F(x+h, y) = F(x, y) \quad y \quad \lim_{h \rightarrow 0^+} F(x, y+h) = F(x, y)$$

(v) Para cada  $(x_1, y_1), (x_2, y_2) \in \mathbb{R}^2$ ,

$$P(x_1 < X \leq x_2, y_1 < Y \leq y_2) = F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1)$$

(vi) Si  $X$  e  $Y$  son variables aleatorias independientes, entonces  $F(x, y) = F_X(x)F_Y(y)$  para todo  $(x, y) \in \mathbb{R}^2$ .

(vii)  $D_{(X,Y)} = D_X \times D_Y$ , donde  $D_{(X,Y)} = \{(x, y) \in \mathbb{R}^2 : p((x, y)) = P(X = x, Y = y) > 0\}$ .

**Demostración.** Los cuatro primeros apartados vienen de reescribir la proposición anterior para el caso bidimensional, mientras que los tres últimos se comprueban fácilmente.  $\square$

**Definición 45.** Dado un vector aleatorio  $(X, Y)$ , la **distribución marginal de  $X$**  no es más que la medida de probabilidad inducida por  $X$ , mientras que la **distribución marginal de  $Y$**  no es más que la medida de probabilidad inducida por  $Y$ .

El ejemplo que sigue demostrará que las cuatro propiedades de la Proposición 29 no caracterizan a las funciones de distribuciones conjuntas, esto es, hay funciones que verifican las propiedades mencionadas y que no son la función de distribución conjunta asociada a ningún vector aleatorio.

**Ejemplo.** Considérese la función  $G: \mathbb{R}^2 \rightarrow [0, 1]$  dada por

$$G(x, y) = \begin{cases} 0 & \text{si } x + y < 1 \\ 1 & \text{si } x + y \geq 1 \end{cases}$$

Si  $G$  fuera la función de distribución conjunta asociada a algún vector aleatorio  $X$ , se tendría

$$P_X((0, 1] \times (0, 1]) = G(1, 1) - G(0, 1) - G(1, 0) + G(0, 0) = -1,$$

lo cual es imposible.

Así, dada una función  $F$ , para asegurar que existe algún vector aleatorio con función de distribución conjunta  $F$  será necesario exigir alguna propiedad adicional.

### 7.3. Diferencia de una función con respecto a un rectángulo

**Definición 46.** Considérese una función  $F: \mathbb{R}^n \rightarrow \mathbb{R}$ , sea  $A = (a, b]$  un rectángulo acotado de  $\mathbb{R}^n$  y sea  $V$  el conjunto de los  $2^n$  vértices de  $A$ . La **diferencia de  $F$  con respecto a  $A$**  se define como

$$\Delta_A F := \sum_{x \in V} \text{sgn}(x) F(x),$$

donde  $\text{sgn}(x) = 1$  si el número de veces que se tiene  $x_i = a_i$  es par, y  $\text{sgn}(x) = -1$  en caso contrario.

La definición puede parecer algo confusa, pero se trata en realidad de un concepto más simple que el mecanismo de un botijo. Por ejemplo, para  $n = 1$ , si  $A = (a, b]$ , la diferencia será

$$\Delta_A F = F(b) - F(a),$$

y para  $n = 2$ , si  $A = (a_1, b_1] \times (a_2, b_2]$ , se tendrá

$$\Delta_A F = F(b_1, b_2) - F(a_1, b_2) - F(b_1, a_2) + F(a_1, a_2)$$

La diferencia de una función con respecto a un rectángulo acotado nos dará la condición que faltaba para asegurar que una función con ciertas propiedades es la función de distribución conjunta de algún vector aleatorio.

**Proposición 31.** Si una función  $F: \mathbb{R}^n \rightarrow [0, 1]$  con las propiedades (i), (ii), (iii) y (iv) que aparecen en la Proposición 29 verifica

(v)  $\Delta_A F \geq 0$  para todo  $A = (a, b] \subset \mathbb{R}^n$ ,

entonces  $F$  es la función de distribución conjunta asociada a algún vector aleatorio  $X$ .

**Demostración.** Requiere más trabajo del que le gustaría al probabilista promedio. □

De aquí en adelante, por motivos de comodidad en la notación, se trabajará exclusivamente con vectores aleatorios bidimensionales.

### 7.4. Vectores aleatorios discretos

**Definición 47.** Un vector aleatorio  $(X, Y): \Omega \rightarrow \mathbb{R}^2$  se dice que es **discreto** si  $X$  e  $Y$  son variables aleatorias discretas.

Quizá habría sido más natural definir los vectores aleatorios discretos de la misma forma que se hizo en el caso unidimensional, es decir, diciendo que *un vector aleatorio es discreto cuando*

$$\sum_{(x,y) \in \mathbb{R}^2} p((x,y)) = \sum_{(x,y) \in D_{(X,Y)}} p((x,y)) = 1$$

Pues bien, si se tiene en cuenta que  $D_{(X,Y)} = D_X \times D_Y$ , es sencillo demostrar que ambas definiciones son equivalentes.

Por otra parte, en cuanto a las distribuciones marginales, si  $D_X = \{x_i : i \in I\}$  es el rango de  $X$  y el de  $Y$  es  $D_Y = \{y_j : j \in J\}$  (obviamente  $I, J \subset \mathbb{N}$ ), entonces

$$P_X(\{x_i\}) = P(X = x_i) = \sum_{j \in J} P(X = x_i, Y = y_j) = \sum_{j \in J} P_{(X,Y)}(\{(x_i, y_j)\}),$$

lo que proporciona una forma de calcular la distribución marginal de  $X$  de un vector aleatorio  $(X, Y)$  a partir de la medida de probabilidad de dicho vector. Evidentemente, de forma análoga,

$$P_Y(\{y_j\}) = P(Y = y_j) = \sum_{i \in I} P(X = x_i, Y = y_j) = \sum_{i \in I} P_{(X,Y)}(\{(x_i, y_j)\})$$

**Definición 48.** Sea  $(X, Y)$  un vector aleatorio discreto y sea  $y_j \in \mathbb{R}$  tal que  $P(Y = y_j) > 0$ . Se define la **variable aleatoria condicionada al suceso  $Y = y_j$** , y se denota  $X|Y = y_j$ , como la variable aleatoria determinada por

$$P(X = x_i | Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)}$$

para cada  $x_i \in \mathbb{R}$ . De forma totalmente análoga se define la **variable aleatoria condicionada al suceso  $X = x_i$** , para cualquier  $x_i \in \mathbb{R}$  que verifique  $P(X = x_i) > 0$ .

**Ejemplo.** Considérese el experimento aleatorio consistente en lanzar una moneda al aire cinco veces. El espacio de probabilidad sería  $(\Omega, \mathcal{P}(\Omega), P)$ , donde  $P$  es la medida uniforme y

$$\Omega = \{CCCCC, FFFFF, CCCCF, CCCFC, CCFCC, \dots\}$$

Sea  $X$  la variable aleatoria que cuenta el número de resultados distintos en el primer lanzamiento, y sea  $Y$  la variable aleatoria que cuenta el número de resultados distintos en el quinto lanzamiento. Por ejemplo, para ilustrar un poco el panorama, se tendría

$$\begin{aligned} X(CCCCC) &= 0 & Y(CCCCC) &= 0 \\ X(CFCFC) &= 2 & Y(CFCFC) &= 2 \\ X(CFFCF) &= 3 & Y(CFFCF) &= 2 \end{aligned}$$

Las probabilidades  $P_X$ ,  $P_Y$  y  $P_{(X,Y)}$  quedan totalmente determinadas por la tabla siguiente:

$\begin{matrix} Y \\ X \end{matrix}$	0	1	2	3	4	$P_X$
0	$\frac{1}{16}$	0	0	0	0	$\frac{1}{16}$
1	0	$\frac{3}{16}$	0	0	$\frac{1}{16}$	$\frac{4}{16}$
2	0	0	$\frac{3}{16}$	$\frac{3}{16}$	0	$\frac{6}{16}$
3	0	0	$\frac{3}{16}$	$\frac{1}{16}$	0	$\frac{4}{16}$
4	0	$\frac{1}{16}$	0	0	0	$\frac{1}{16}$
$P_Y$	$\frac{1}{16}$	$\frac{4}{16}$	$\frac{6}{16}$	$\frac{4}{16}$	$\frac{1}{16}$	1

Por ejemplo, si se quisiera calcular la probabilidad de  $(0, 0)$ , sería

$$\begin{aligned} P_{(X,Y)}(\{(0,0)\}) &= P(X=0, Y=0) = P(\{CCCCC, FFFFF\}) \\ &= P(\{CCCCC\}) + P(\{FFFFF\}) = \frac{1}{2^5} + \frac{1}{2^5} = \frac{1}{16} \end{aligned}$$

Por último, va a tratar de calcularse la distribución de probabilidad de la variable aleatoria  $X|Y=1$ , cuyo rango es  $D_{X|Y=1} = \{1, 4\}$ . Se tiene que

$$\begin{aligned} P_{X|Y=1}(\{1\}) &= P(X=1|Y=1) = \frac{P(X=1, Y=1)}{P(Y=1)} = \frac{3/16}{4/16} = \frac{3}{4} \\ P_{X|Y=1}(\{4\}) &= P(X=4|Y=1) = \frac{P(X=4, Y=1)}{P(Y=1)} = \frac{1/16}{4/16} = \frac{1}{4} \end{aligned}$$

**Ejemplo.** Sea  $(X, Y)$  un vector aleatorio discreto y sean  $D_X = \{0, 1, 2, 3\}$  y  $D_Y = \{1, 2, 3\}$  los rangos de  $X$  e  $Y$ , respectivamente. Supóngase además que  $Y \sim U(\{1, 2, 3\})$  y que para todo  $y \in D_Y$  se tiene que  $X|Y=y \sim \text{Bin}(y, \frac{1}{2})$ . Se va a tratar de obtener la distribución conjunta de  $(X, Y)$ , es decir, de calcular

$$P(X = x_i, Y = y_j) = P(X = x_i | Y = y_j)P(Y = y_j),$$

siendo  $D_X = \{x_i : i = 1, 2, 3, 4\}$  y  $D_Y = \{y_j : j = 1, 2, 3\}$ . Fijando, por ejemplo  $y_1 = 1$ , se tiene que

$$P(X = 0, Y = 1) = P(X = 0 | Y = 1)P(Y = 1) = \binom{1}{0} \frac{1}{2^0} \frac{1}{2^1} \frac{1}{3} = \frac{1}{6}$$

$$P(X = 1, Y = 1) = P(X = 1 | Y = 1)P(Y = 1) = \binom{1}{1} \frac{1}{2^1} \frac{1}{2^0} \frac{1}{3} = \frac{1}{6}$$

$$< P(X = 2, Y = 1) = P(X = 2 | Y = 1)P(Y = 1) = 0$$

$$P(X = 3, Y = 1) = P(X = 3 | Y = 1)P(Y = 1) = 0$$

Realizando estas mismas cuentas para  $y = 2$  e  $y = 3$  queda resuelto el ejemplo.

**Ejemplo.** Sea  $(X, Y)$  un vector discreto y supongamos que  $Y \sim U(\{1, 2, 3\})$ , que  $X | Y = y \sim \text{Bin}(y, \frac{1}{2})$  para cada  $y \in D_Y = \{1, 2, 3\}$  y que  $D_{X|Y=y} = \{0, 1, \dots, y\}$ . La distribución conjunta de  $(X, Y)$  ahora es

$X \backslash Y$	1	2	3	$P_X$
0	$\frac{1}{6}$	$\frac{1}{12}$	$\frac{1}{24}$	$\frac{7}{24}$
1	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{8}$	$\frac{11}{24}$
2	0	$\frac{1}{12}$	$\frac{1}{8}$	$\frac{5}{24}$
3	0	0	$\frac{1}{24}$	$\frac{1}{24}$
$P_Y$	$\frac{8}{24}$	$\frac{8}{24}$	$\frac{8}{24}$	1

Se va a exponer el cálculo de, por ejemplo,  $P(X = 0, Y = 2)$ . Se tiene que

$$P(X = 0, Y = 2) = P(X = 0 | Y = 2)P(Y = 2) = \binom{2}{0} \frac{1}{2^0} \frac{1}{2^2} \frac{1}{3} = \frac{1}{12}$$

**Ejemplo.** Supóngase que el número de huevos de insectos encima de una flor sigue una distribución de Poisson de parámetro  $\lambda > 0$  (es decir,  $\lambda$  es la frecuencia media con la que los insectos ponen huevos). Supóngase además que, fijado un intervalo de tiempo, la probabilidad de que un huevo eclosiona es  $p \in (0, 1)$ . Los objetivos del ejemplo son

- (i) Calcular la probabilidad de que no nazca ningún insecto en dicho intervalo de tiempo. Al traducir el panorama al universo de las matemáticas, se observa que hay calcular  $P(X = 0)$ , donde

$$X \equiv \text{número de huevos en la flor que han eclosionado}$$

Asimismo, considérese la variable aleatoria

$$Y \equiv \text{número de huevos en la flor}$$

Nótese que  $D_X = D_Y = \mathbb{N}$ , que  $Y \sim P(\lambda)$  y que  $X | Y = n \sim \text{Bin}(n, p)$  para cada  $n \in \mathbb{N}$ . Además,

$$\begin{aligned} P(X = 0) &= \sum_{n=0}^{\infty} P(X = 0, Y = n) = \sum_{n=0}^{\infty} P(X = 0 | Y = n)P(Y = n) = \sum_{n=0}^{\infty} (1-p)^n e^{-\lambda} \frac{\lambda^n}{n!} \\ &= e^{-\lambda} \sum_{n=0}^{\infty} \frac{(\lambda(1-p))^n}{n!} = e^{-\lambda} e^{\lambda(1-p)} = e^{-\lambda p} \end{aligned}$$

- (ii) Calcular la probabilidad de que nazcan  $k$  insectos en dicho intervalo de tiempo. Razonando como

antes, ahora es menester calcular  $P(X = k)$ . Se tiene que

$$\begin{aligned} P(X = k) &= \sum_{n=0}^{\infty} P(X = k, Y = n) = \sum_{n=0}^{\infty} P(X = k | Y = n) P(Y = n) \\ &= \sum_{n=k}^{\infty} \binom{n}{k} p^k (1-p)^{n-k} e^{-\lambda} \frac{\lambda^n}{n!} = \sum_{n=k}^{\infty} \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} e^{-\lambda} \frac{\lambda^n}{n!} \\ &= \frac{\lambda^k p^k e^{-\lambda}}{k!} \sum_{n=k}^{\infty} \frac{(\lambda(1-p))^{n-k}}{(n-k)!} = \frac{\lambda^k p^k e^{-\lambda} e^{\lambda(1-p)}}{k!} = e^{-\lambda p} \frac{(\lambda p)^k}{k!} \end{aligned}$$

Esto demuestra que  $X \sim P(\lambda p)$ .

- (iii) Calcular de que hubiesen menos de dos huevos en la flor tras haber observado que no ha nacido ningún insecto. Se trata de calcular  $P(Y < 2 | X = 0)$ , para lo que habrá que echar mano del teorema de Bayes.

$$\begin{aligned} P(Y < 2 | X = 0) &= P(Y = 0 | X = 0) + P(Y = 1 | X = 0) \\ &= \frac{P(X = 0 | Y = 0) P(Y = 0)}{P(X = 0)} + \frac{P(X = 0 | Y = 1) P(Y = 1)}{P(X = 0)} \\ &= \frac{e^{-\lambda}}{e^{-\lambda p}} + \frac{(1-p)e^{-\lambda} \lambda}{e^{-\lambda p}} \\ &= \frac{1 + \lambda(1-p)}{e^p} \end{aligned}$$

## 7.5. Vectores aleatorios absolutamente continuos

**Definición 49.** Un vector aleatorio  $(X, Y)$  con función de distribución conjunta  $F: \mathbb{R}^2 \rightarrow [0, 1]$  se dice que es **absolutamente continuo** (o que posee una distribución de probabilidad **absolutamente continua**) si existe una función  $f: \mathbb{R}^2 \rightarrow \mathbb{R}$  integrable y no negativa tal que

$$F(x, y) = \int_{-\infty}^y \int_{-\infty}^x f(u, v) du dv$$

para cada  $(x, y) \in \mathbb{R}^2$ . La función  $f$  se denominará **función de densidad conjunta**.

**Proposición 32.** Sea  $(X, Y)$  un vector aleatorio absolutamente continuo con probabilidad inducida  $P_{(X,Y)}$ , función de distribución  $F$  y función de densidad conjunta  $f$ . Entonces

- (i) Se verifica que

$$\int_{\mathbb{R}^2} f(u, v) du dv = 1$$

- (ii) Para todo  $B \in \mathcal{B}^2$ ,

$$P_{(X,Y)}(B) = \int_B f(u, v) du dv$$

- (iii) Para todo  $(x_0, y_0) \in \mathbb{R}^2$ ,

$$\frac{\partial^2 F(x_0, y_0)}{\partial x \partial y} = \frac{\partial^2 F(x_0, y_0)}{\partial y \partial x} = f(x_0, y_0)$$

- (iv)  $X$  e  $Y$  son variables aleatorias absolutamente continuas con funciones de densidad

$$f_X(x) = \int_{\mathbb{R}} f(x, y) dy \quad y \quad f_Y(y) = \int_{\mathbb{R}} f(x, y) dx$$

- (v) Si  $y_0 \in \mathbb{R}$  es tal que  $f_Y(y_0) > 0$ , entonces la variable aleatoria  $X|_{Y=y_0}$  es absolutamente continua

y su función de densidad es

$$f_{X|Y=y_0}(x) = \frac{f(x, y_0)}{f_Y(y_0)}$$

(vi) Si  $x_0 \in \mathbb{R}$  es tal que  $f_X(x_0) > 0$ , entonces la variable aleatoria  $Y|_{X=x_0}$  es absolutamente continua y su función de densidad es

$$f_{Y|X=x_0}(y) = \frac{f(x_0, y)}{f_X(x_0)}$$

(vii) Si  $X$  e  $Y$  son variables independientes, entonces  $f(x, y) = f_X(x)f_Y(y)$  para todo  $(x, y) \in \mathbb{R}^2$ .

**Demostración.** Tampoco. □

Obsérvese que puede que  $X$  e  $Y$  sean variables aleatorias absolutamente continuas y el vector aleatorio  $(X, Y)$  no sea absolutamente continuo (tómese  $Y = X$ , por ejemplo).

**Proposición 33 (Cambio de variable).** Sea  $(X, Y)$  un vector aleatorio absolutamente continuo con densidad conjunta  $f_{(X,Y)}$ , y sea  $T \subset \mathbb{R}$  el conjunto de puntos donde  $f_{(X,Y)}$  toma valores positivos. Sea  $g: T \rightarrow \mathbb{R}^2$  una función inyectiva y diferenciable tal que, para todo  $(u, v) \in T$ ,

$$\det Jg(u, v) = \begin{vmatrix} \frac{\partial g_1}{\partial u}(u, v) & \frac{\partial g_1}{\partial v}(u, v) \\ \frac{\partial g_2}{\partial u}(u, v) & \frac{\partial g_2}{\partial v}(u, v) \end{vmatrix} \neq 0$$

Entonces  $(U, V) = g(X, Y)$  es un vector aleatorio absolutamente continuo, con densidad

$$f_{(U,V)}(u, v) = f_{(X,Y)}(g^{-1}(u, v)) |\det Jg(g^{-1}(u, v))|^{-1}$$

**Demostración.** Utilícese el teorema de la función inversa. □

**Ejemplo.** Sea  $(X, Y)$  un vector aleatorio absolutamente continuo con densidad conjunta

$$f(x, y) = \begin{cases} x + y & \text{si } 0 < x < 1 \\ 0 & \text{en caso contrario} \end{cases}$$

Se tratará de calcular la función de distribución conjunta  $F$ . Sea  $(x, y) \in \mathbb{R}^2$ .

(i) Si  $x < 0$  o  $y < 0$ ,

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y 0 \, du \, dv = 0$$

(ii) Si  $0 < x < 1$  y  $0 < y < 1$ ,

$$F(x, y) = \int_0^x \int_0^y (u + v) \, dv \, du = \int_0^x \left[ uv + \frac{v^2}{2} \right]_0^y \, du = \left[ \frac{u^2 y}{2} + \frac{u y^2}{2} \right]_0^x = \frac{x^2 y + x y^2}{2}$$

(iii) Si  $0 < x < 1$  y  $1 \leq y$ ,

$$F(x, y) = \int_0^x \int_0^1 (u + v) \, du \, dv = \frac{x^2 + x}{2}$$

(iv) Si  $1 \leq x$  y  $0 < y < 1$ ,

$$F(x, y) = \int_0^1 \int_0^y (u + v) \, du \, dv = \frac{y^2 + y}{2}$$

(v) Si  $1 \leq x$  y  $1 \leq y$ ,

$$F(x, y) = \int_0^1 \int_0^1 (u + v) \, du \, dv = 1$$

**Ejemplo.** Sea  $(X, Y)$  un vector aleatorio absolutamente continuo con función de densidad dada por

$$f(x, y) = \begin{cases} ax^2y & \text{si } 0 < y < x < 1 \\ 0 & \text{en caso contrario} \end{cases}$$

Los propósitos del ejemplo son

(i) Calcular el valor de  $a$ . Debe cumplirse lo siguiente:

$$\int_{\mathbb{R}^2} f(x, y) dx dy = 1$$

Se tiene que

$$\int_0^1 \int_0^x ax^2y dy dx = \int_0^1 \left[ \frac{ay^2x^2}{2} \right]_0^x dx = \int_0^1 \frac{ax^4}{2} dx = \left[ \frac{ax^5}{10} \right]_0^1 = \frac{a}{10},$$

de donde se deduce que  $a = 10$ .

(ii) Hallar las distribuciones marginales. Si  $0 < x < 1$ ,

$$f_X(x) = \int_{\mathbb{R}} f(x, y) dy = \int_0^x 10yx^2 dy = \left[ 5y^2x^2 \right]_0^x = 5x^4$$

Por tanto,

$$f_X(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ 5x^4 & \text{si } 0 < x < 1 \\ 5x^2 & \text{si } 1 \leq x \end{cases}$$

Por otra parte, si  $0 < y < 1$ ,

$$f_Y(y) = \int_{\mathbb{R}} f(x, y) dx = \int_y^1 10yx^2 dx = \left[ \frac{10yx^3}{3} \right]_y^1 = \frac{10y}{3} - \frac{10y^4}{3}$$

En consecuencia,

$$f_Y(y) = \begin{cases} \frac{10y}{3} & \text{si } y \leq 0 \\ \frac{10y}{3}(1 - y^3) & \text{si } 0 < y < 1 \\ 0 & \text{si } 1 \leq y, \end{cases}$$

con lo que quedan determinadas las distribuciones marginales de  $X$  e  $Y$ .

(iii) Hallar las densidades de las variables aleatorias  $X|_{Y=y_0}$  e  $Y|_{X=x_0}$ , donde  $x_0, y_0 \in (0, 1)$ . En primer lugar, si  $y_0 < x < 1$ ,

$$f_{X|Y=y_0}(x) = \frac{f(x, y_0)}{f_Y(y_0)} = \frac{10y_0x^2}{\frac{10y_0}{3}(1 - y_0^3)} = \frac{3x^2}{1 - y_0^3}$$

Por tanto,

$$f_{X|Y=y_0}(x) = \begin{cases} \frac{3x^2}{1 - y_0^3} & \text{si } y_0 < x < 1 \\ 0 & \text{en caso contrario} \end{cases}$$

Por otra parte, si  $0 < y < x_0$ ,

$$f_{Y|X=x_0}(y) = \frac{f(x_0, y)}{f_X(x_0)} = \frac{10yx_0^2}{5x_0^4} = \frac{2y}{x_0^2}$$



En consecuencia,

$$f_{Y|X=x_0}(y) = \begin{cases} \frac{2y}{x_0^2} & \text{si } 0 < y < x_0 \\ 0 & \text{en caso contrario} \end{cases}$$

(iv) Calcular la esperanza de la variable aleatoria  $Y|_{X=\frac{1}{2}}$ . Se tiene que

$$E[Y|_{X=\frac{1}{2}}] = \int_{\mathbb{R}} y f_{Y|_{X=\frac{1}{2}}}(y) dy = \int_0^{\frac{1}{2}} 8y^2 dy = \left[ \frac{8y^3}{3} \right]_0^{\frac{1}{2}} = \frac{1}{3}$$

**Ejemplo.** Sea  $(X, Y)$  un vector aleatorio absolutamente continuo con densidad conjunta

$$f(x, y) = \begin{cases} e^{-x-y} & \text{si } x > 0, y > 0 \\ 0 & \text{en caso contrario} \end{cases}$$

Se tratará de hallar la distribución de la variable aleatoria  $U = \frac{X}{X+Y}$ . Para ello, considérense la variable  $V = X + Y$  y el vector  $(U, V) = g(X, Y)$ , donde

$$\begin{aligned} g: T &\longrightarrow \mathbb{R}^2 \\ (x, y) &\longmapsto g(x, y) = \left( \frac{x}{x+y}, x+y \right), \end{aligned}$$

siendo  $T = \{(x, y) \in \mathbb{R}^2 : x > 0, y > 0\}$ . Se tiene que  $g$  es inyectiva y diferenciable, y si  $(x, y) \in T$ ,

$$\det Jg(x, y) = \begin{vmatrix} \frac{\partial g_1}{\partial x}(x, y) & \frac{\partial g_1}{\partial y}(x, y) \\ \frac{\partial g_2}{\partial x}(x, y) & \frac{\partial g_2}{\partial y}(x, y) \end{vmatrix} = \begin{vmatrix} \frac{y}{(x+y)^2} & -\frac{x}{(x+y)^2} \\ 1 & 1 \end{vmatrix} = \frac{1}{x+y} \neq 0$$

Además, la inversa de  $g$  viene dada por  $g^{-1}(u, v) = (uv, v(1-u))$ , luego

$$\det Jg(g^{-1}(u, v)) = \frac{1}{v}$$

Se concluye que  $(U, V)$  es una variable aleatoria absolutamente continua con función de densidad

$$f_{(U,V)}(u, v) = v e^{-uv-v(1-u)} = v e^{-v},$$

siempre que  $(u, v) \in g(T)$ . Ya puede hallarse fácilmente la función de densidad de  $U$ .

# Teorema central del límite

## 8.1. Convergencia en distribución

**Definición 50.** Sea  $\{X_n\}_{n=1}^\infty$  una sucesión de variables aleatorias, y sean  $\{F_n\}_{n=1}^\infty$  sus funciones de distribución. Se dice que **la sucesión  $\{X_n\}_{n=1}^\infty$  converge en distribución a la variable aleatoria  $X$** , si

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

para todo  $x \in C_F = \{x \in \mathbb{R} : F \text{ es continua en } x\}$ , siendo  $F$  la función de distribución de  $X$ . Se suele denotar

$$X_n \xrightarrow[n \rightarrow \infty]{d} X$$

## 8.2. Teorema central del límite

**Teorema 7.** Si  $X$  es una variable aleatoria absolutamente continua con  $X \sim N(\mu, \sigma^2)$ , entonces

$$\frac{X - \mu}{\sigma} \sim N(0, 1)$$

**Demostración.** Sea  $\varphi: \mathbb{R} \rightarrow \mathbb{R}$  la función definida por

$$\varphi(x) = \frac{x - \mu}{\sigma}$$

La función  $\varphi$  es una función de Borel (pues es continua), es derivable, tiene derivada continua y es estrictamente monótona. El teorema del cambio de variable permite afirmar que

$$Z = \varphi \circ X = \frac{X - \mu}{\sigma}$$

es una variable aleatoria absolutamente continua, y su densidad es

$$f_Y(y) = f_X(\varphi^{-1}(y)) |(\varphi^{-1})'(y)|,$$

donde  $\varphi^{-1}: \mathbb{R} \rightarrow \mathbb{R}$  está definida por  $\varphi^{-1}(y) = \sigma y + \mu$ . Por tanto,

$$f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{(\sigma y + \mu - \mu)^2}{2\sigma^2}} |\sigma| = \frac{|\sigma|}{\sqrt{2\pi}|\sigma|} e^{-\frac{\sigma^2 y^2}{2\sigma^2}} = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}},$$

concluyéndose que  $Z \sim N(0, 1)$ . □

Este teorema permite reducir el cálculo de probabilidades de distribuciones normales cualesquiera al cálculo de probabilidades de la distribución normal estándar, pues si  $X \sim N(\mu, \sigma^2)$ , entonces, para cada  $a \in \mathbb{R}$ ,

$$P(X < a) = P\left(\frac{X - \mu}{\sigma} < \frac{a - \mu}{\sigma}\right) = P\left(Z < \frac{a - \mu}{\sigma}\right),$$

donde  $Z \sim N(0, 1)$ .

**Teorema 8 (Teorema central del límite de Lindeberg-Lévy).** Consideremos una sucesión de variables aleatorias  $\{X_n\}_{n=1}^{\infty}$  verificando:

- (i) Las variables aleatorias son mutuamente independientes.
- (ii) Todas las variables aleatorias tienen la misma distribución de probabilidad.
- (iii) Existen  $\mu = E[X_n]$  y  $\sigma^2 = \text{Var}[X_n]$ .

Entonces

$$\frac{S_n - n\mu}{\sqrt{n}\sigma} \xrightarrow[n \rightarrow \infty]{d} N(0, 1),$$

donde  $S_n = X_1 + \dots + X_n$  para cada  $n \in \mathbb{N}$ .

**Demostración.** No hace falta. □

**Corolario 3 (Teorema de De Moivre-Laplace).** Sea  $\{X_n\}_{n=1}^{\infty}$  una sucesión de variables aleatorias mutuamente independientes tales que  $X_n \sim \text{Ber}(p)$  para todo  $n \in \mathbb{N}$ . Entonces

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow[n \rightarrow \infty]{d} N(0, 1),$$

donde  $S_n = X_1 + \dots + X_n$  para cada  $n \in \mathbb{N}$ .

**Demostración.** Consecuencia inmediata del teorema anterior. □

La importancia de este corolario radica en que, para un natural  $n$  lo suficientemente grande, se verifica

$$\text{Bin}(n, p) \approx N(np, np(1-p))$$

Esto se debe a que la variable aleatoria  $S_n$  del corolario anterior sigue una distribución binomial de parámetros  $n$  y  $p$ , siendo  $\mu = np$  y  $\sigma^2 = np(1-p)$  su esperanza y su varianza. Por tanto,

$$\frac{S_n - \mu}{\sigma} \approx N(0, 1),$$

así que se podría decir que

$$\text{Bin}(n, p) \approx N(\mu, \sigma^2) = N(np, np(1-p))$$